



МИНОБРНАУКИ РОССИИ

Федеральное государственное бюджетное образовательное учреждение
высшего образования

«МИРЭА – Российский технологический университет»

РТУ МИРЭА

Институт информационных технологий (ИИТ)

Кафедра прикладной математики (ПМ)

КУРСОВАЯ РАБОТА

по дисциплине

«Прогнозно-аналитические системы»

Тема курсовой работы: «Анализ данных оценок проданных книг с использованием ПО Loginom»

Студент группы ИМБО-01-20

Черных Анастасия Николаевна

(подпись)

Руководитель
курсовой работы

доцент, к.т.н., Скляр А.Я.

(подпись)

Работа представлена к защите

«_28_»__декабря____2023 г.

Допущен к защите

«_28_»__декабря____2023 г.

Москва 2023 г.

СОДЕРЖАНИЕ

ВВЕДЕНИЕ.....	3
1 ТЕОРЕТИЧЕСКАЯ ЧАСТЬ	4
1.1 Кластерный анализ.....	4
1.2 Корреляционный анализ.....	8
1.3 Регулярные выражения.....	10
2 ПРАКТИЧЕСКАЯ ЧАСТЬ	11
ЗАКЛЮЧЕНИЕ	23
СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ	23
ПРИЛОЖЕНИЯ.....	25

ВВЕДЕНИЕ

Анализ данных играет важную роль в современном бизнесе, обеспечивая информированные и обоснованные решения на основе фактических данных. В данной курсовой работе мы сфокусируемся на анализе данных о продажах книг с использованием программного обеспечения Loginom.

Мир книжной индустрии переживает значительные трансформации: в условиях современных технологий цифровые и аудиокниги становятся все более популярными, а традиционные книжные магазины конкурируют с онлайн-платформами. Анализ данных о продажах книг может помочь издательским домам, книжным магазинам и авторам понять предпочтения читателей, определить тенденции и принять обоснованные стратегические решения.

Целью данной курсовой работы является проведение анализа данных о продажах книг с использованием программного обеспечения Loginom.

Для проведения данного анализа мы воспользуемся программным комплексом Loginom, предоставляющим широкий набор инструментов для решения задач анализа данных и построения моделей. Мы также планируем использовать статистический и визуализационный анализ для обработки полученных данных и выявления важных закономерностей.

Задачи, решаемые в ходе курсовой работы:

- изучить документацию и техническую литературу по исследуемой теме;
- реализация алгоритмов для предобработки данных;
- реализация алгоритмов для анализа данных;
- визуализация полученных результатов;
- изучение правил качественного оформления документации.

1 ТЕОРЕТИЧЕСКАЯ ЧАСТЬ

1.1 Кластерный анализ

Кластерный анализ (от англ. cluster analysis) – совокупность многомерных статистических методов классификации объектов по характеризующим их признакам, разделение совокупности объектов на однородные группы, близкие по определяющим критериям, выделение объектов определенной группы. Он предназначен для разбиения совокупности объектов на однородные группы, которые также называют кластерами или классами.

Кластер – это группы объектов, выделенные в результате кластерного анализа на основе заданной меры сходства или различий между объектами. Объект – это конкретные предметы исследования, которые необходимо классифицировать. Объектами при классификации выступают, как правило, наблюдения. Например, потребители продукции, страны или регионы, товары и т.п.




Рисунок 1 – Визуальное представление кластеров

Классификация объектов в многомерном кластерном анализе происходит по нескольким признакам одновременно. Это могут быть как количественные, так и категориальные переменные в зависимости от метода кластерного

анализа. Главная цель кластерного анализа – нахождение групп схожих объектов в выборке.

Существует два вида многомерных статистических методов кластерного анализа:

- иерархические методы (агломеративные и дивизимные);
- неиерархические (метод k -средних, двухэтапный кластерный анализ, метод ближайших соседей).

Наиболее часто используемые из них - это оба метода иерархического кластерного анализа и кластеризация методом k -средних. Сущность этих иерархического кластерного анализа заключается в том, что на первом шаге каждый объект рассматривается как отдельный кластер. Процесс объединения кластеров происходит последовательно: на основании матрицы расстояний или матрицы сходства объединяются наиболее близкие объекты. Если матрица сходства первоначально имеет размерность $n \times n$, то полностью процесс кластеризации завершается за $n - 1$ шагов, в итоге все объекты будут объединены в один кластер.

В общем виде алгоритм иерархического кластерного анализа можно представить в виде последовательности процедур:

1. Значения исходных переменных нормируются.
2. Рассчитывается матрица расстояний или матрица мер близости.
3. Находится пара самых близких кластеров. По выбранному алгоритму объединяются эти два кластера. Новому кластеру присваивается меньший из номеров объединяемых кластеров.
4. Пункты 2, 3 и 4 повторяются до тех пор, пока все объекты не будут объединены в один кластер или до достижения заданного "порога" близости.

Иерархические методы объединения, хотя и точны, но трудоёмки: на каждом шаге необходимо выстраивать дистанционную матрицу для всех текущих кластеров. Расчётное время растёт пропорционально третьей степени

количества наблюдений, что при наличии нескольких тысяч наблюдений может утомить и серьёзные вычислительные машины.

В то же время, метод кластеризации k -средних позволяет разделить объекты на заданное число кластеров в соответствии с критерием, представляющим собой статистику Фишера: отношение межкластерной дисперсии к внутрикластерной. В результате разделение осуществляется так, чтобы изменчивость переменных внутри кластеров была малой, между кластерами - большой. Иными словами, объекты, входящие в один и тот же кластер, были расположены в пространстве переменных близко, а входящие в разные кластеры - далеко друг от друга.

В отличие от иерархических методов метод k -средних не рассматривает все возможные варианты разбиения на заданное число кластеров. Начиная работу с какого-то, как правило, произвольного варианта, метод последовательно меняет разбиение до тех пор, пока критерий оптимизации не перестает меняться. В силу этого, если на пути алгоритма встретился не глобальный максимум критерия, а лишь некоторый из локальных, метод может прекратить свою работу, не дойдя до глобально оптимального разбиения. Поэтому при его использовании очень важны начальные условия. Другая же проблема при работе с данным методом состоит в том, что исследователю приходится из каких-то соображений задавать число кластеров. В этом нам на помощь приходит «метод локтя».

Для реализации «метода локтя» строится график зависимости функции стоимости от числа кластеров. С ростом числа кластеров значение функции стоимости уменьшается. Количество кластеров, где происходит «перелом» графика, берут в качестве k .




Рисунок 1.1 — Выбор количества кластеров с помощью «метода локтя»

Но не всегда такой метод позволяет понять, какое же количество кластеров взять. Почему на предыдущем графике выбор пал на $k=4$? Почему не 5?

Существует еще способ определения количества кластеров — коэффициент силуэта. Он наиболее понятен и аргументирован, так как коэффициент силуэта демонстрирует пиковое значение, нежели плавный изгиб в методе локтя.

Коэффициент силуэта рассчитывается с использованием среднего внутрикластерного расстояния a и среднего расстояния до ближайшего кластера b для каждой выборки. Коэффициент силуэта s для выборки по формуле:

$$s = \frac{b - a}{\max(a, b)} \quad (1)$$




Рисунок 1.2 — Выбор количества кластеров с помощью «метода локтя»

Если рассматривать глобально, то можно отметить, что кластеризация является одной из фундаментальных задач в области анализа данных и Data Mining. Список прикладных областей, где она применяется, широк: сегментация изображений, маркетинг, борьба с мошенничеством, прогнозирование, анализ текстов и многие другие. Кластерный анализ хорошо зарекомендовал себя во всех сферах жизнедеятельности человека. Прелесть данного метода - он работает даже тогда, когда данных мало и не выполняются требования нормальности распределений случайных величин и другие требования классических методов статистического анализа.

1.2 Корреляционный анализ

Корреляционный анализ - это статистический метод, направленный на изучение степени взаимосвязи между переменными. Он позволяет определить, насколько сильно две или более переменные связаны между собой. Корреляция может быть положительной, при которой обе переменные растут вместе;

отрицательной, где одна переменная убывает, когда другая растет, или отсутствовать вообще.

Рассмотрим, какие виды корреляций существуют. Выделяют три вида корреляционного анализа:

- Пирсоновская корреляция;
- Спирменовская корреляция;
- корреляция Кендалла.

В low-code платформе Logiном корреляционный анализ реализован с помощью коэффициента Пирсона. Стоит отметить, что данный коэффициент измеряет силу и направление линейной связи между двумя непрерывными переменными. Значение коэффициента корреляции находится в диапазоне от -1 до 1. Значение ближе к 1 показывает сильную положительную корреляцию, к -1 - сильную отрицательную, а значение около 0 свидетельствует об отсутствии корреляции.

Корреляционный анализ имеет широкую область применения. Например, в науке и исследованиях: в медицине, социологии, психологии и других научных областях корреляционный анализ используется для оценки взаимосвязи между различными переменными, такими как здоровье и образ жизни, социальное поведение и факторы окружающей среды. Также он полезен в сфере бизнеса и финансов: в бизнесе корреляционный анализ помогает выявить связь между различными переменными, такими как объем продаж и затраты на рекламу, чтобы понять, какие факторы влияют на успех бизнеса. Не стоит забывать и про прогнозирование, так как корреляционный анализ используется для предсказания будущих значений переменных на основе их взаимосвязи.

Результаты корреляционного анализа могут помочь в выявлении тенденций, создании моделей прогнозирования, а также в принятии обоснованных решений на основе статистических данных.

Но никакой анализ нельзя произвести без правильно предобработанных данных. В случае заполнения данных человеческой рукой, нам не обойтись без регулярных выражений.

1.3 Регулярные выражения

Регулярные выражения представляют собой последовательности символов, которые создают шаблоны поиска. Они служат для эффективного и гибкого поиска, обработки и изменения текста и строк.

Рассмотрим основные принципы работы регулярных выражений.

Во-первых, их синтаксис включает в себя как обычные символы, так и метасимволы. Метасимволы — это выражения, помогающие указать наборы символов. В регулярных выражениях широко применяются такие метасимволы, как «^», «\$», «.», «*», «+», «?».

Во-вторых, регулярные выражения позволяют создавать группы символов и применять к ним квантификаторы — специальные символы, определяющие количество повторений.

С помощью описанного функционала регулярных выражений, появляется возможность широко применять их в программировании для обработки текста, в обработке текстовых данных и в веб-разработке, а также для валидации данных, обработки и поиска текста, автоматизации обработки текстовых файлов.

Используя описанный выше теоретический материал, перейдём к реализации практической части данной курсовой работы.

2 ПРАКТИЧЕСКАЯ ЧАСТЬ

Для выполнения данной курсовой работы были использованы данные о продаже книг с сайта Amazon.

Обратимся к основному источнику наших данных и рассмотрим его подробнее.

Amazon - американская компания, крупнейшая в мире на рынках платформ электронной коммерции и публично-облачных вычислений по выручке и рыночной капитализации, штаб-квартира которой находится в Сиэтле.

Если обратиться к истории компании, то можно заметить, что в 5 июля 1994 года основатель Amazon, Джефф Безос, решил начать свой бизнес с онлайн-торговли книгами, осознавая потенциал интернета для расширения ассортимента и улучшения доступности книжных товаров. Этот решительный шаг привел к созданию одной из крупнейших онлайн-платформ для покупки книг и других товаров, однако книги остаются одним из приоритетов для компании.

Amazon предлагает огромный каталог книг по различным темам, жанрам и авторам. Пользователи имеют возможность приобретать как электронные, так и печатные книги, в том числе новинки, бестселлеры и редкие издания. Система рекомендаций, основанная на предпочтениях и покупках, помогает пользователям обнаруживать новые книги и авторов.

Amazon предлагает удобный поиск книг, подробные описания, отзывы пользователей и возможность предварительного чтения фрагментов книг. Приобретение товаров через Amazon также обеспечивает уверенность в качестве обслуживания, доставки и возможности возврата или обмена продукции, что является важным фактором для покупателей.

Amazon продолжает инновации в цифровой сфере, предлагая Kindle - собственное устройство для чтения электронных книг. Это дополняет их

репутацию как лидера в продаже книг и укрепляет положение компании как одной из наиболее влиятельных в мире торговых площадок.

Amazon остается важным игроком в индустрии продажи книг и играет важную роль в формировании предпочтений читателей, распространении книжной культуры и развитии цифровых технологий чтения. Именно поэтому для своей курсовой работы я выбрала данные именно этой компании.

Данные включают в себя 18 столбцов: title (название книги), author (автор или авторы книги), price: цена (в долларах), price including used books (диапазон цен на новые и подержанные книги (в долларах)), pages (количество страниц), avg_reviews (средняя оценка (от 1 до 5)), n_reviews (количество отзывов для каждой книги), star5 (процент отзывов с пятью звездами), star4 (процент отзывов с четырьмя звездами), star3 (процент отзывов с тремя звездами), star2 (процент отзывов с двумя звездами), star1 (процент отзывов с одной звездой), psize (размер книги в дюймах), weight (вес в фунтах или унциях), language (язык книги), publisher (издатель), ISBN-13: код ISBN-13, link (ссылка на книгу на Amazon), complete_link (полная ссылка на книгу на Amazon (включая домен «https://amazon.com»)).

Подключим описанный выше датасет к нашему сценарию Loginom, выбрав модуль «Текстовый файл». (Рисунок 2.1)

Импорт из текстового файла

Хранилище файлов: Локальное

Имя файла: books/final_book_dataset_kaggle2.csv

Кодовая страница: ANSI/Windows (0)

Заголовок в первой строке: ☒ Пропустить строк: 0

```
title,author,price,price (including used books),pages,avg_reviews,n_reviews,star5,star4,star3,star2,star1,dimensions,weight,language
Data Analysis Using R (Low Priced Edition): A Primer for Data Scientist,[ Dr Dhaval Maheta],6.75,6.75,500,4.4,23,55%,39%,6%,,,8.5 x 11
"Head First Data Analysis: A learner's guide to big numbers, statistics, and good decisions",,33.72, 21.49 - 33.72,484,4.3,124,61%,2
Guerrilla Data Analysis Using Microsoft Excel: Overcoming Crap Data and Excel Skirmishes,[ Oz du Soleil, and , Bill Jelen],32.07,3
"Python for Data Analysis: Data Wrangling with Pandas, NumPy, and IPython",[ William McKinney],53.99,53.99,547,4.6,"1,686",75%,16%,5%
Excel Data Analysis For Dummies (For Dummies (Computer/Tech)),[ Paul McFedries],24.49,24.49,368,3.9,12,52%,17%,10%,10%,10%,7.38 x 0.8
Everything Data Analytics: A Beginner's Guide to Data Literacy: Understanding the Processes That Turn Data Into Insights,,,,,4.2,31,6
SQL for Data Analysis: Advanced Techniques for Transforming Data into Insights,[ Cathy Tanimura],40.49,40.49,360,4.6,72,75%,18%,2%,2%
Qualitative Data Analysis: A Methods Sourcebook,[ Matthew B. Miles, A. Michael Huberman, et al.],90,90,408,4.7,205,84%,9%,4%,2%,8.
Topological Data Analysis with Applications,"[ Gunnar Carlsson, and , Mikael Vejdemo-Johansson]",54.19, 53.98 - 54.19,230,5.5,100%
"R in Action, Third Edition: Data analysis and graphics with R and Tidyverse",[ Robert I. Kabacoff],56.99, 47.97 - 56.99,656,4.3,14
"Listening to People: A Practical Guide to Interviewing, Participant Observation, Data Analysis, and Writing It All Up (Chicago Guide
SQL for Data Analytics: Perform efficient and fast data analysis with the power of SQL,[ Chad Knowles],15.97,15.97,106,4.9,201,91%,8%
Python for Beginners: 2 Books in 1: The Perfect Beginner's Guide to Learning How to Program with Python with a Crash Course + Workboo
"Data Analytics, Data Visualization & Communicating Data: 3 books in 1: Learn the Processes of Data Analytics and Data Science, Creat
Getting Started with Natural Language Processing,[ Ekaterina Kochmar],39.99,39.99,456,4.4,48%,52%,,,7.38 x 1.1 x 9.25 inches,1.75 po
"SQL QuickStart Guide: The Simplified Beginner's Guide to Managing, Analyzing, and Manipulating Data With SQL",[ Walter Shields],24.9
Monty Python And The Holy Grail,,,,,,,,,,,,,/Monty-Python-Grail-Graham-Chapman/dp/B07PGCJM9V/ref=sr_1_54?keywords=python&qid=167
Python in easy steps,,10.69,10.69,192,4.6,386,74%,14%,8%,2%,2%,7.25 x 0.5 x 9 inches,15.2 ounces,English,"In Easy Steps Limited; 2nd
Python para Principiantes: 2 Libros en 1: Programaci7n de Python para principiantes + Libro de trabajo de Python (Spanish Edition),[
Quantum Machine Learning and Optimisation in Finance: On the Road to Quantum Advantage,"[ Antoine Jacquier, Oleksiy Kondratyev, et a
```

Рисунок 2.1 — Импорт датасета в сценарий

Заметим, что для правильного отображения следует в качестве разделителя установить запятую. В получившейся таблице убираем галочку с тех столбцов, которые, из соображений здравого смысла, мы посчитали не несущими ценность для предстоящего анализа. (Рисунок 2.2, Рисунок 2.3)

Обновить все	Обновить данные	Кол-во строк для анализа	26				
Поля	ab title	ab author	9.0 price	9.0 price (includi...	9.0 pages	9.0 avg_reviews	9.0 n_review
Имя	title	author	price	COL4	pages	avg_reviews	n_reviews
Метка	title	author	price	price (including ...	pages	avg_reviews	n_reviews
Тип данных	ab Строковый	ab Строковый	9.0 Вещественный	9.0 Вещественный	9.0 Вещественный	9.0 Вещественный	9.0 Веществ
Вид данных	Дискретный	Дискретный	Непрерывный	Непрерывный	Непрерывный	Непрерывный	Непрерыв
Использовать	☒	☒	☒	☐	☒	☒	☒
1	Data Analysis Us...	[Dr Dhaval Mahe...	6.75		500.00	4.40	
2	Head First Data ...		33.72		484.00	4.30	
3	Guerrilla Data A...	[Oz du Soleil, an...	32.07		274.00	4.70	
4	Python for Data ...	[William McKinn...	53.99		547.00	4.60	
5	Excel Data Analy...	[Paul McFedries]	24.49		368.00	3.90	
6	Everything Data ...					4.20	
7	SQL for Data Ana...	[Cathy Tanimura]	40.49		360.00	4.60	
8	Qualitative Data ...	[Matthew B. Mil...	90.00		408.00	4.70	
9	Topological Data...	[Gunnar Carlsson...	54.19		230.00	5.00	
26							

Рисунок 2.2 — Избавление от ненужных столбцов

Обновить все		Обновить данные		Кол-во строк для анализа		26	
Поля	nsions	ab weight	ab language	ab publisher	ab ISBN_13	ab link	ab complete_link
Имя	ons	weight	language	publisher	ISBN_13	link	complete_link
Метка	ons	weight	language	publisher	ISBN_13	link	complete_link
Тип данных	ковый	ab Строковый	ab Строковый	ab Строковый	ab Строковый	ab Строковый	ab Строковый
Вид данных	ретный	Дискретный	Дискретный	Дискретный	Дискретный	Дискретный	Дискретный
Использовать	☒	☒	☒	☒	☐	☐	☐
	1 x 11 in...	2.53 pounds	English	Notion Press Me...			
	2 x 9.25 in...	1.96 pounds	English	O'Reilly Media; 1...			
	3 x 5 x 10.75...	1.4 pounds	English	Holy Macro! Boo...			
	4 x 9.19 in...	1.47 pounds	English	O'Reilly Media; 2...			
	5 x 8.3 x 9.25...	1.3 pounds	English	For Dummies; 5t...			
	6						
	7 x 7.5 x 8.75...	1.2 pounds	English	O'Reilly Media; 1...			
	8 x 2 x 11 in...	2.15 pounds	English	SAGE Publicatio...			
	9 x 7.5 x 9.75...	1.28 pounds	English	Cambridge Univ...			
26							

Рисунок 2.3 — Избавление от ненужных столбцов

Далее добавим модуль «Заполнение пропусков» и настроим его так. Как показано на Рисунке 2.4.

№	Входные поля	Вид данных	☒	Метод обработки
	Фильтрация			
1	ab title	Дискретный	☒	Удалять записи
2	ab author	Дискретный	☒	Удалять записи
3	9.0 price	Непрерывный	☒	Удалять записи
4	9.0 pages	Непрерывный	☒	Удалять записи
5	9.0 avg_reviews	Непрерывный	☒	Удалять записи
6	9.0 n_reviews	Непрерывный	☒	Удалять записи
7	ab star5	Дискретный	☒	Заменять значением "Не задано"
8	ab star4	Дискретный	☒	Заменять значением "Не задано"
9	ab star3	Дискретный	☒	Заменять значением "Не задано"
10	ab star2	Дискретный	☒	Заменять значением "Не задано"
11	ab star1	Дискретный	☒	Заменять значением "Не задано"
12	ab dimensions	Дискретный	☒	Удалять записи
13	ab weight	Дискретный	☒	Удалять записи
14	ab language	Дискретный	☒	Удалять записи
15	ab publisher	Дискретный	☒	Удалять записи

Рисунок 2.4 — Настройки модуля «Заполнение пропусков»

После выполнения предыдущего модуля данные всё ещё имеют пропущенные значения, поэтому для их ликвидации воспользуемся модулем «Фильтр строк». Его настройки представлены на рисунке ниже (Рисунок 2.5)

Фильтрация данных

Состояние входа: Не активировано [Активировать](#)

ab author = × [или](#)
ab title = × [или](#)
ab publisher = × [или](#)
9.0 avg_reviews = ×

[или](#)
ab publisher пустое × [или](#)
ab weight = ×
+

Рисунок 2.5 — Настройки модуля «Фильтр строк»

Таким образом, мы избавились от пропущенных значений. Однако необходимые данные всё ещё не имеют подходящий для обработки формат. Конкретно обратим внимание на столбцы:

- publisher (написан не только издатель, но и дата издания в строковом формате);
- weight (вес представлен в строковом формате и в разных величинах);
- star5, star4, star3, star2, star1 (процентное содержание имеет строковый формат).

Добавим модуль «Калькулятор» и обработаем указанные выше недостатки данных. Код для обработки представлен ниже на рисунках 2.6 — 2.15

```
If (star5 = "", 0, Val(Replace(star5, "%", "")))/100
```

Рисунок 2.6 — Перевод значений столбца Star5 в числовой формат с запятой (для Star4, Star 3, Star2, Star1 аналогичен)

```
RegexReplace("\((.*)\)", RegexReplace("\;.+", publisher, ""), "")
```

Рисунок 2.7 — Получение издательства из столбца Publisher

```
RegexReplace(".*\(", RegexReplace("\)", publisher, ""), "")
```

Рисунок 2.8 — Получение строковой даты из столбца Publisher

```
If (Count(RegexMatchedExp("[0-9]{1,2}", date))=1,  
Concat("0", RegexMatchedExp("[0-9]{1,2}", date)),  
RegexMatchedExp("[0-9]{1,2}", date))
```

Рисунок 2.9 — Получение дня из даты и перевод его в формат с двумя цифрами

```
RegexMatchedExp("[A-Za-z]{3}", date)
```

Рисунок 2.10 — Получение первых трёх букв месяца из даты

```
Right(date, 2)
```

Рисунок 2.11 — Получение года из даты

```
Replace(Replace(Replace(Replace  
(Replace(Replace(Replace  
(Replace(Replace(Replace(Replace  
Replace(w_month, "Dec", "12"), "Nov", "11"), "Oct", "10"), "Sep", "09"),  
"Aug", "08"), "Jul", "07"), "Jun", "06"), "May", "05"), "Apr", "04"),  
"Mar", "03"), "Feb", "02"), "Jan", "01")
```

Рисунок 2.12 — Перевод месяцев в числовой формат

```
Concat(day, ".", month, ".", year)
```

Рисунок 2.13 — Сбор даты в необходимый далее формат

```
StrtoDate(pr_date, "DD.MM.YY")
```

Рисунок 2.14 — Перевод полученной даты из строкового формата в формат даты

```
If (RegexMatchedExp("[a-z]{1,}", weight) = "ounces",  
    (Val(RegexMatchedExp("[0-9.]{1,}", weight))) * 28.35,  
    If (RegexMatchedExp("[a-z]{1,}", weight) = "pounds",  
        (Val(RegexMatchedExp("[0-9.]{1,}", weight))) * 453.6, 0))
```

Рисунок 2.15 — Получение веса из столбца Weight и перевод веса книг из унций и фунтов в граммы

Начнём производить анализ предобработанными данными. Для этого добавим модуль «Группировка» и сгруппируем данные по издательствам (Рисунок 2.16)

  	
Выбранные поля 	
 Группа	
ab publisher	
 Показатели	
9.0 price (Сумма, Количество, Среднее)	
9.0 avg_reviews (Среднее)	

Рисунок 2.16 — Настройка модуля «Группировка»

Полученная таблица, содержащая 107 издательств и отсортированная в порядке убывания количества книг, представлена на Рисунке 2.17

#	ab publisher	9.0 price Сум...	12 price Количество	9.0 price Среднее	9.0 avg_reviews Средн...
1	Packt Publishing	3004.88	68	44.18941176	4.461764706
2	O'Reilly Media	2352.81	56	42.01446429	4.458928571
3	Independently published	1256.38	55	22.84327273	4.416363636
4	Wiley	1088.74	26	41.87461538	4.426923077
5	Packt Publishing	836.68	19	44.03578947	4.473684211
6	Cambridge University Press	722.62	13	55.58615385	4.484615385
7	No Starch Press	426.89	13	32.83769231	4.607692308
8	No Starch Press	385.12	13	29.62461538	4.684615385
9	For Dummies	253.64	12	21.13666667	4.383333333
10	Manning	516.51	11	46.95545455	4.454545455
11	Pearson	1495.15	10	149.515	4.46
12	Manning	356.37	9	39.59666667	4.477777778
13	SAGE Publications Ltd	440.67	9	48.96333333	4.688888889
14	Kogan Page	212.78	7	30.39714286	4.5
15	Cengage Learning	686.95	7	98.13571429	4.257142857
16	Princeton University Press	189.95	6	31.65833333	4.616666667
17	Wiley-Interscience	457.89	5	91.578	4.5
18	SAGE Publications, Inc	309.07	4	77.2675	4.55
19	Apress	188.37	4	47.0925	4.45
20	Routledge	184.72	4	46.18	4.325
21	Princeton University Press	90.89	4	22.7225	4.575
22	Microsoft Press	115.95	4	28.9875	4.375
23	Springer	298.05	3	99.35	4.5
107	The MIT Press	229.36	3	76.45333333	4.7

Рисунок 2.17 — Сгруппированная по столбцу Publisher таблица

Заметим, что Packt Publishing имеет не только самое большое количество книг, но и самую большую общую стоимость продаваемых книг.

Проведём корреляционный анализ, чтобы найти возможные зависимости между параметрами. Матрица критерия Пирсона представлена ниже в Таблице 2.1

Таблица 2.1

	price	pages	avg_reviews	n_reviews	weight
price	1	0.506	−0.048	−0.142	0.393
pages	−0.506	1	0.019	−0.06	0.726
avg_reviews	0.048	−0.019	1	0.111	0.019
n_reviews	0.142	0.06	−0.111	1	−0.043
weight	−0.393	−0.726	−0.019	0.043	1

Заметим, что наибольший коэффициент Пирсона присущ зависимости между количеством страниц и весом книги, что неудивительно и поддаётся здравому смыслу, отчего не даёт нам новых данных. Однако, также можем обратить внимание на зависимость цены от количества страниц — чем больше страниц в книге, тем она дороже. Можем также упомянуть менее значимую зависимость, которую можно также выделить в ходе корреляционного анализа, — это зависимость между ценой и весом книги, которая оценивается коэффициентом Пирсона как 0.393, то есть, средняя и не особо значительная.

Так как у количества страниц и веса книги сильная корреляция, попробуем провести регрессионный анализ и предсказать количество страниц в книге по её весу.

Для этого воспользуемся модулем «Разбиение на множества» для разбития данных на обучающую и тестовую выборку (80% и 20%, соответственно), а также подключим модуль «Линейная регрессия». Далее оценим точность предсказания, подсчитав разницу между предсказанными значениями и реальными. Результаты представлены на Рисунке 2.18.

#	точность Δ	pages Регрессия	вес (r)	ра...	Доля 5 звезд	Доля 4 звезд	Доля 3 звезд	Доля 2 звезд	Доля 1 звезды	publisher
1	0.01405511044	199.405511	100.0755	198	0.77	0.18	0.05	0	0	Rockridge Press
2	0.02894489713	394.8944897	689.472	392	0.69	0.22	0.09	0	0	SAGE Publications, Inc
3	0.03109754561	467.1097546	907.2	464	0.55	0.21	0.12	0.12	0	Artech House
4	0.05105510287	394.8944897	689.472	400	0.69	0.13	0.11	0.03	0.05	Wiley-Interscience
5	0.05988908494	434.0110915	807.408	440	0.77	0.1	0.07	0.07	0	Manning
6	0.06204173342	361.7958267	589.68	368	0.77	0.13	0.06	0.02	0.02	O'Reilly Media
7	0.06345158186	378.3451582	639.576	372	0.6	0.21	0.08	0.08	0.03	Packt Publishing
8	0.07105510287	394.8944897	689.472	402	0.76	0.15	0.09	0	0	Packt Publishing
9	0.08004322177	264.0043222	294.84	256	0.71	0.14	0.11	0.02	0.03	Harvard Business Review Press
10	0.08237525762	342.2375258	530.712	334	0.58	0.26	0.16	0	0	O'Reilly Media
11	0.1299315277	427.9931528	789.264	415	1	0	0	0	0	Springer
12	0.1324902019	346.7509798	544.32	360	0.75	0.18	0.02	0.02	0.02	O'Reilly Media
13	0.1369071929	366.3092807	603.288	380	0.73	0.15	0.06	0.02	0.04	O'Reilly Media
14	0.1468174992	369.3182501	612.36	384	0.72	0.14	0.08	0.06	0	O'Reilly Media
15	0.1500212214	431.0021221	798.336	416	0.83	0.11	0.03	0.02	0.01	No Starch Press
16	0.171593265	376.8406735	635.04	394	0.76	0.11	0.05	0.08	0	O'Reilly Media
17	0.2119520397	364.804796	598.752	386	0.69	0.13	0.11	0.04	0.03	Packt Publishing
18	0.2293036719	406.9303672	725.76	384	0.79	0.16	0.03	0.02	0	No Starch Press
19	0.2319267892	327.1926789	485.352	304	0.75	0.15	0.06	0.02	0.02	O'Reilly Media
20	0.2506963281	406.9303672	725.76	432	0.7	0.16	0.08	0.04	0.02	Wiley
21	0.2579582666	361.7958267	589.68	336	0.66	0.16	0.13	0.03	0.03	O'Reilly Media
22	0.2604272471	415.9572753	752.976	442	0.33	0.3	0.21	0.06	0.1	Packt Publishing
23	0.274575157	444.5424843	839.16	472	0.81	0.1	0.09	0	0	Manning
93	0.2775004018	346.7500402	552.302	322	0.56	0.16	0.07	0.1	0.11	Packt Publishing

Рисунок 2.18 — Результаты оценки точности прогноза

Отметим, что, чем ближе значение точности к нулю, тем точнее получилось предсказание. Визуализируем полученные данные на графике (Рисунок 2.19).




Рисунок 2.19 — Сравнение реальных и спрогнозированных значений

Далее проведём кластерный анализ и выделим группы книг, в соответствии с ним. Для этого нам сначала нужно определить количество кластеров. Воспользуемся модулем «Python», чтобы написать код для подсчёта коэффициентов локтя и силуэта для диапазона от двух до десяти кластеров. Код для описанной задачи представлен в приложении Б.

Посмотрим график по полученным коэффициентам и оценим результаты (Рисунок 2.20 — Рисунок 2.21).




Рисунок 2.20 — Коэффициент силуэта кластеров




Рисунок 2.21 — Коэффициент метода локтя

Как и было описано в теоретической части, метод локтя существенно уступает коэффициенту силуэта кластеров при плавном уменьшении стоимости кластеров. На графике это наглядно видно, так как прямая получилась очень плавной. Можно сказать, что наш локоть не согнут.

Поэтому обратимся к результирующему графику метода силуэта, на котором явно виден пик в виде двух кластеров.

Добавим в наш проект модуль «Кластеризация» и зададим в качестве параметра «Заданное число кластеров» 2 кластера (Рисунок 2.20)

Кластеризация

Автоопределение числа кластеров ☐

Заданное число кластеров

Число кластеров

Автоматическое определение числа кластеров

Минимальное число кластеров

Максимальное число кластеров

Порог разделения кластеров

Рисунок 2.22 — Настройки модуля «Кластеризация»

Оценим полученные кластеры (Рисунок 2.21).

	avg_re...	n_revie...	pages	price	вес	Доля 5 ...
0	4.51	81.67	644.47	72.18	1,153.15	0.75
1	4.47	110.67	312.88	33.56	551.42	0.73
Итого:	4.48	102.71	403.96	44.17	716.70	0.74

Рисунок 2.23 — Полученные кластеры

Как мы можем заметить, в первый кластер попали книги с большим количеством страниц, дорогой ценой и большим весом, которые мало читают. Можем предположить, что это группа учебной литературы, написанной тяжёлым для понимания языком. Тогда как во второй кластер попали короткие, лёгкие и дешёвые книги, на которые гораздо чаще оставляют отзывы. Скорее всего, это книги жанра научпоп. Заметим, что отзывы оказывают малое влияние на формирование кластеров, значит, качественной книга может быть вне зависимости от популярности, количества страниц или веса.

Напоследок оценим данные книг по месяцам, произведя группировку. Результаты представлены на Рисунке 2.22

#	9.0 price Сре...	9.0 pages Сре...	9.0 n_reviews С...	12 title Количе...	9.0 вес (г) Сре...	ab m... 1
1	12.99	300	410	1	861.84	
2	53.37	425.2790698	5934	43	777.6075349	01
3	46.17774194	466.4516129	2428	31	726.098371	02
4	45.38272727	376.9393939	3217	33	621.5651591	03
5	48.50868421	419.4473684	4914	38	694.7018289	04
6	44.8096875	401.5	2290	32	637.0510781	05
7	46.56433333	436.4333333	3083	30	751.9932	06
8	43.256	430.3666667	3405	30	815.4594	07
9	44.43525	398.875	3759	40	733.315275	08
10	41.51119048	365.2142857	4139	42	690.525	09
11	46.355	357.8846154	4336	52	737.6997115	10
12	34.3506	352.64	4126	50	619.64595	11
13	39.22363636	464.4090909	5821	44	799.4893295	12

Рисунок 2.24 — Группировка данных по месяцам

Из данной таблицы видно, что меньше всего книг было выпущено в феврале, что можно соотнести с недавно прошедшими долгими праздниками и невозможностью влиться в рабочий режим. В то же время, самым плодотворным месяцем на производство книг можно считать ноябрь — месяц, когда все пытаются к новому году закончить все дела.

Таким образом, мы произвели анализ данных и сделали выводы.

ЗАКЛЮЧЕНИЕ

В ходе данной курсовой работы мы провели анализ данных о продажах книг с использованием программного обеспечения Loginom.

Использование ПО Loginom значительно упростило процесс анализа данных и позволило оперативно получить ценные инсайты, способствующие развитию бизнес-стратегий в сфере книжной индустрии.

Данное исследование является важным шагом в направлении понимания предпочтений читателей, определения бизнес-стратегий и разработки маркетинговых кампаний. Полученные результаты могут быть использованы в различных областях, включая издательское дело, маркетинговые исследования, и управление ассортиментом.

В целом, данная курсовая работа подтверждает значимость анализа данных для принятия обоснованных решений в индустрии продаж книг, и является основой для дальнейших исследований в данной области.

В ходе данной курсовой работы выполнены следующие задачи:

- изучена документацию и техническую литературу по исследуемой теме;
- реализованы алгоритмы для предобработки данных;
- реализованы алгоритмы для анализа данных;
- визуализированы полученные результаты;
- изучены правила качественного оформления документации.

СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ

ТЕОРЕТИЧЕСКАЯ ЧАСТЬ

- 1.1. Миркин Б.Г., Введение в анализ данных. Учебник и практикум / Миркин Б.Г. – Москва: Юрайт, 2015. – 176 с.
- 1.2. Гитис Л.Х., Статистическая классификация и кластерный анализ / Гитис Л.Х. – Москва: Издательство МГГУ, 2003. – 157 с.
- 1.3. Дюран Б., Кластерный анализ / Дюран Б., Оделл П., Демиденко Е.З. – Москва: Книга по Требованию, 2012. – 128 с.
- 1.4. Публичная веб-платформа “Kaggle” [Электронный ресурс] / Air Quality in Madrid (2001-2018). — Режим доступа: <https://www.kaggle.com/decide-soluciones/air-quality-madrid/>. — Загл. с экрана. — Яз. англ.

ПРАКТИЧЕСКАЯ ЧАСТЬ


- 2.1 Loginom Community [Электронный ресурс]. — Режим доступа: <https://loginom.ru/>
- 2.2 Kaggle. Amazon Data Science Books Dataset [Электронный ресурс]. — Режим доступа: <https://www.kaggle.com/datasets/die9origephit/amazon-data-science-books>

ПРИЛОЖЕНИЯ

Приложение А — Полный сценарий программы.

Приложение Б — Программный код на Python для подсчёта коэффициентов метода локтя и метода силуэтов

Приложение А



Приложение Б

```
import builtin_data
from builtin_data import InputTable, InputTables, InputVariables, OutputTable,
DataType, DataKind, UsageType
from builtin_pandas_utils import to_data_frame, prepare_compatible_table, fill_table
import numpy as np
import pandas as pd
import math
from sklearn.cluster import KMeans
from sklearn.metrics import silhouette_score
if InputTable:
    # Создать pd.DataFrame по входному набору №1
    input_frame = to_data_frame(InputTable)
score1 = []
score2 = []
for i in range(2,10):
    model = KMeans(n_clusters=i, random_state=123, init='k-
means++').fit(input_frame)
    score1.append(silhouette_score(input_frame, model.labels_))
    score2.append(model.inertia_)
output_frame = pd.DataFrame({"n_clusters": [2,3,4,5,6,7,8,9], "coeff_silhouette":
score1, "coeff_elbow": score2})
print(output_frame)
if isinstance(OutputTable, builtin_data.ConfigurableOutputTableClass):
    prepare_compatible_table(OutputTable, output_frame, with_index=False)
fill_table(OutputTable, output_frame, with_index=False)
```