



МИНОБРНАУКИ РОССИИ

Федеральное государственное бюджетное образовательное учреждение
высшего образования

«МИРЭА – Российский технологический университет»
РТУ МИРЭА

Институт информационных технологий
кафедра прикладной математики

КУРСОВАЯ РАБОТА

по дисциплине

Прикладные задачи математической статистики

(наименование дисциплины)

Тема курсовой работы

Исследование статистических методов анализа данных

Студент группы

Имбо-01-20, Черных Анастасия Николаевна,

(учебная группа Ф.И.О. студента)

(подпись студента)

Руководитель курсовой работы

Буданцев А.В.

(должность, звание, учёная степень Ф.И.О.)

(подпись руководителя)

Рецензент (при наличии)

(должность, звание, учёная степень Ф.И.О.)

(подпись рецензента)

Работа представлена к защите

« 2 » _____ мая _____ 2023 г.

Допущен к защите

« _____ » _____ 2022 г.

Москва 2022 г.



МИНОБРНАУКИ РОССИИ

Федеральное государственное бюджетное образовательное учреждение
высшего образования
«МИРЭА – Российский технологический университет»
РТУ МИРЭА

Институт информационных технологий
кафедра прикладной математики

Утверждаю

Заведующий кафедрой
Держинский Р.И.

подпись

Ф.И.О.

«__» _____ 2022 г.

ЗАДАНИЕ

на выполнение курсовой работы по дисциплине

Прикладные задачи математической статистики

Студент _____ Черных Анастасия Николаевна _____ Группа _____ ИМБО-01-20

Тема: _____ Исследование статистических методов анализа данных _____

Исходные данные: _____ Исходные данные выданы в соответствии с вариантом

Перечень вопросов, подлежащих разработке, и обязательного графического материала: 1. Расчет статистических параметров. 2. Интервальные оценки параметров. Доверительные интервалы точечных оценок. 3. Идентификация распределений. 4. Генерация распределений. Проверка определений известных распределений. 5. Линейная регрессия. Оценка адекватности модели, оценка доверительных интервалов параметров. 6. Сглаживание временных рядов.

Срок представления к защите курсовой работы до «__» _____ 20__ г.

Задание на курсовую работу выдал

подпись руководителя

Буданцев А.В.

Ф.И.О. руководителя

Задание на курсовую работу получил

подпись обучающегося

«__» _____ 20__ г.

Черных А.Н.

Ф.И.О. обучающегося

ОТЗЫВ
на курсовую работу по дисциплине

Прикладные задачи математической статистики

Студент Черных Анастасия Николаевна группы ИМБО-01-20
(ФИО студента)

Характеристика курсовой работы

Критерий	Да	Нет	Не полностью
1. Соответствие содержания курсовой работы указанной теме			
2. Соответствие курсовой работы заданию			
3. Соответствие рекомендациям по оформлению текста, таблиц, рисунков и пр.			
4. Полнота выполнения всех пунктов задания			
5. Логичность и системность содержания курсовой работы			
6. Отсутствие фактических грубых ошибок			

Замечания:

Рекомендуемая оценка:

подпись руководителя

Буданцев А.В.
ФИО руководителя

СОДЕРЖАНИЕ

ВВЕДЕНИЕ	5
1 РАСЧЕТ СТАТИСТИЧЕСКИХ ПАРАМЕТРОВ	7
1.1 Постановка задачи.....	7
1.2 Выполнение задачи	8
2 ДОВЕРИТЕЛЬНЫЕ ИНТЕРВАЛЫ ТОЧЕЧНЫХ ОЦЕНОК.....	15
2.1 Постановка задачи.....	15
2.2 Выполнение задачи	17
3 ИДЕНТИФИКАЦИЯ РАСПРЕДЕЛЕНИЙ	20
3.1 Постановка задачи.....	20
3.2 Выполнение задачи	23
4 ГЕНЕРАЦИЯ РАСПРЕДЕЛЕНИЙ.....	48
4.1 Постановка задачи.....	48
4.2 Выполнение задачи	51
5 ОЦЕНКА АДЕКВАТНОСТИ МОДЕЛИ, ОЦЕНКА ДОВЕРИТЕЛЬНЫХ ИНТЕРВАЛОВ ПАРАМЕТРОВ.....	58
5.1 Постановка задачи.....	58
5.2 Выполнение задачи	63
6 СГЛАЖИВАНИЕ ВРЕМЕННЫХ РЯДОВ.....	73
6.1 Постановка задачи.....	73
6.2 Выполнение задачи	75
ЗАКЛЮЧЕНИЕ	84
СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ	85

ВВЕДЕНИЕ

Статистика, как любая другая наука, возникла из практических потребностей людей, ищущих возможность упростить свою жизнь с помощью рационализации. Возникновение и развитие капитализма потребовало обширной и достоверной информации о состоянии производства, источниках сырья, рынках труда и сбыта продукции и т.п. Накопление опыта в сборе, систематизации и обработке первичных статистических материалов привёл к быстрому росту потребности в их анализе для выявления закономерностей общественного развития. Таким образом, в современных условиях развития общества значительно вырос интерес к статистике как науке и ее широкому применению в практической деятельности. Сегодня уже никто не может отрицать значение и недооценивать роль статистики в общественной жизни.

Без статистической информации невозможно познание закономерностей природных и социальных массовых явлений, их предвидение, а значит, и регулирование либо прямое управление, будь то на уровне отдельного предприятия, города или региона, на государственном или межгосударственном уровне.

Поэтому данная тема курсовой работы является актуальной для многих сфер жизни: экономической, социальной, политической, - всех сфер, где требуется анализ данных.

В данной курсовой работе решаются следующие задачи:

- расчет статистических параметров;
- построение доверительного интервала точечных оценок;
- идентификация распределений;
- генерация распределений;
- оценка адекватности моделей;
- сглаживание временных рядов.

Цель курсовой работы — применение знаний, полученных на курсе «Прикладные задачи математической статистики».

1 РАСЧЕТ СТАТИСТИЧЕСКИХ ПАРАМЕТРОВ

1.1 Постановка задачи

1. Необходимо собрать данные о том в какие месяца года были рождены студенты группы.
2. Необходимо собрать данные о том какие числа загаданы каждым студентом группы в диапазоне от 0 до 8.
3. Построить полигон относительно частоты для полученных дискретных рядов распределения.
4. Найти выборочное среднее для рядов распределения.
5. Найти выборочную дисперсию для рядов распределения.
6. Найти выборочное СКО для рядов распределения.
7. Найти коэффициент вариации для рядов распределения.
8. Найти эмпирическую функцию распределения.

Выборочное среднее считается по формуле (1.1):

$$\bar{x}_B = \frac{1}{n} \sum_{i=1}^n x_i \quad (1.1)$$

Выборочная дисперсия считается по формуле (1.2):

$$D_B = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x}_i)^2 \quad (1.2)$$

Выборочное среднеквадратичное отклонение считается по формуле (1.3):

$$\sigma_B = \sqrt{D_B} \quad (1.3)$$

Коэффициент вариации считается по формуле (1.4):

$$V_B = \frac{\sigma_B}{\bar{x}_B} \cdot 100\% \quad (1.4)$$

Выполним задачу в соответствии с заданием, в ходе выполнения воспользуемся собранным инструментарием.

1.2 Выполнение задачи

Начнём выполнение задачи с ряда распределения загаданных студентами чисел. Для полученных в результате опроса данных запишем относительную частоту и запишем их в удобном виде (Таблица 1.1).

Таблица 1.1 — Частота выбора случайного числа от 0 до 8

X_i	0	1	2	3	4	5	6	7
N_i	2	1	3	4	1	3	4	3
W_i	0.1	0.05	0.15	0.20	0.05	0.15	0.20	0.15

Построим полигон относительной частоты выбора студентами случайного числа от 0 до 8 (Рисунок 1.1). По оси X отложим загаданные числа, а по оси Y относительную частоту их выбора [1.1].




Рисунок 1.1 — Полигон относительной частоты выбора случайного числа от 0 до 8

Найдем выборочное среднее по формуле выборочного среднего для вариационного ряда **Error! Reference source not found..**

$$\text{Получаем: } \bar{x}_B = \frac{1}{20} (0 \cdot 2 + 1 \cdot 1 + \dots + 6 \cdot 4 + 7 \cdot 3) = 3.9$$

Найдем выборочную дисперсию по формуле выборочной дисперсии для вариационного ряда **Error! Reference source not found..**

$$\begin{aligned} \text{Получаем: } D_B &= \frac{1}{20} (2(0 - \bar{x}_B)^2 + 1(1 - \bar{x}_B)^2 + \dots + 4(6 - \bar{x}_B)^2 + \\ &3(7 - \bar{x}_B)^2) = \frac{1}{20} (2(0 - 3.9)^2 + 1(1 - 3.9)^2 + \dots + 4(6 - 3.9)^2 + \\ &3(7 - 3.9)^2) = 5.09 \end{aligned}$$

Найдем СКО по формуле среднеквадратичного отклонения для вариационного ряда **Error! Reference source not found..**

$$\text{Получаем: } \sigma_B = \sqrt{5.09} = 2.2561$$

Найдем коэффициент вариации по формуле коэффициента вариации для вариационного ряда **Error! Reference source not found..**

$$\text{Получаем: } V_B = \frac{2.2561}{3.9} \cdot 100\% = 57.8488$$

Найдём и построим эмпирическую функцию распределения (Рисунок 1.2)




Рисунок 1.2 — Эмпирическая функция распределения частоты выбора случайного числа от 0 до 8

Приведем формулу (1.5) эмпирической функции распределения [1.2], по которой был построен график.

$$F^*(x) = \begin{cases} 0, & x < 0 \\ 0.1, & 0 \leq x < 1 \\ 0.15, & 1 \leq x < 2 \\ 0.3, & 2 \leq x < 3 \\ 0.5, & 3 \leq x < 4 \\ 0.55, & 4 \leq x < 5 \\ 0.65, & 5 \leq x < 6 \\ 0.85, & 6 \leq x < 7 \\ 1, & x > 7 \end{cases} \quad .(1.5)$$

Отообразим плотность распределения (Рисунок 1.5).




Рисунок 1.3 — Плотность эмпирической функции распределения частоты выбора случайного числа от 0 до 8

Таким образом, задача для первой выборки полностью выполнена. Приступим к выполнению задания для распределения длины рук студентов.

Полученные в результате опроса данные разделим на классы и запишем в удобном виде (Таблица 1.2).

Таблица 1.2 — Длина рук студентов и её разделение по классам

$\{X_i\}$	{67, 70, 70}	{71, 71, 74, 74}	{75, 75, 75, 75, 77, 77}	{79, 79, 79, 79, 80, 81}	{86}
N_i	3	4	6	6	1
$[a_i, b_i]$	[67, 70.8)	[70.8, 74.6)	[74.6, 78.4)	[78.4, 82.2)	[82.2, 86]

Построим гистограмму классов распределения длины рук студентов (Рисунок 1.3). По оси X отложим длину рук, а по оси Y количество элементов в получившихся классах.




Рисунок 1.4 — Гистограмма классов распределения длины рук («Роста») студентов

Найдем выборочное среднее по формуле выборочного среднего для вариационного ряда **Error! Reference source not found..**

$$\text{Получаем: } \bar{x}_B = \frac{1}{20} (67 + 2 \cdot 70 + \dots + 81 + 86) = 75.7$$

Найдем выборочную дисперсию по формуле выборочной дисперсии для вариационного ряда **Error! Reference source not found..**

$$\begin{aligned} \text{Получаем: } D_B &= \frac{1}{20} ((67 - \bar{x}_B)^2 + 2(70 - \bar{x}_B)^2 + \dots + (81 - \bar{x}_B)^2 + \\ & (86 - \bar{x}_B)^2) = \frac{1}{20} ((67 - 75.7)^2 + 2(70 - 75.7)^2 + \dots + (81 - 75.7)^2 + \\ & (86 - 75.7)^2) = 18.804 \end{aligned}$$

Найдем СКО по формуле среднеквадратичного отклонения для вариационного ряда **Error! Reference source not found..**

$$\text{Получаем: } \sigma_B = \sqrt{18.804} = 4.3364$$

Найдем коэффициент вариации по формуле коэффициента вариации для вариационного ряда **Error! Reference source not found..**

$$\text{Получаем: } V_B = \frac{4.3364}{75.7} \cdot 100\% = 5.7283$$

Найдём и построим эмпирическую функцию распределения (Рисунок 1.4)




Рисунок 1.5 — Эмпирическая функция распределения классов длины рук («Роста») студентов

Приведем формулу (1.6) эмпирической функции распределения, по которой был построен график.

$$F^*(x) = \begin{cases} 0, & x < 67 \\ 0.15, & 67 \leq x < 70.8 \\ 0.35, & 70.8 \leq x < 74.6 \\ 0.65, & 74.6 \leq x < 78.4 \\ 0.95, & 78.4 \leq x < 82.2 \\ 1, & x \geq 82.2 \end{cases} \quad .(1.6)$$

Отообразим плотность распределения (Рисунок 1.5).




Рисунок 1.6 — Плотность эмпирической функции распределения классов длины рук («Роста») студентов

Таким образом, задача для второй выборки полностью выполнена.

По итогу мы провели работу по сбору данных и по расчёту статистических параметров для них. Рассчитанные параметры включают выборочное среднее, выборочную дисперсию, выборочное среднеквадратичное отклонение, а также коэффициент вариации. По полученным вариационным рядам нами были построены полигоны частот и эмпирические функции распределений. Для наглядности нами были построены графики найденных эмпирических функций.

2 ДОВЕРИТЕЛЬНЫЕ ИНТЕРВАЛЫ ТОЧЕЧНЫХ ОЦЕНОК

2.1 Постановка задачи

1. Скачать папку с исходными данными по ссылке.
2. Открыть папку, соответствующую номеру своей группы.
3. Открыть папку, соответствующую номеру своего варианта.
4. В папке data можете найти 4 ряда данных реализации случайной величины.
5. Для каждого из четырех рядов данных необходимо провести следующие расчёты:
 - подсчитать выборочные статистики для среднего и стандартного отклонения;
 - для выборочного среднего $\bar{x}_в$ подсчитать границы доверительного интервала по правилу нормального распределения, используя таблицу критических значений функции Лапласа $\Phi(x)$ и по правилу t-распределения Стьюдента используя таблицу критических значений $t_{\gamma,n}$ t-распределения при значении уверенности $\gamma = 0.95$;
 - для выборочного среднеквадратического отклонения $\sigma_в$ подсчитать границы доверительного интервала по оценке χ^2 -распределения при значении уверенности $\gamma = 0.95$.

Выборочное среднее вычисляется по формуле (2.1):

$$\bar{x}_в = \frac{1}{N} \sum_{i=1}^N x_i, \quad (2.1)$$

где N — число значений реализации случайной величины;

$x_i \in \mathbb{R}, i \in \overline{1, N}$ — реализации нашей случайной величины.

Выборочное среднеквадратическое отклонение вычисляется по формуле (2.2):

$$\sigma_B = \sqrt{\frac{\sum_{i=1}^N (x_i - \bar{x}_B)^2}{N - 1}}. \quad (2.2)$$

Границы доверительного интервала по правилу нормального распределения находятся по формуле (2.3):

$$\hat{x}_B \in \left[\bar{x}_B - x_\gamma + \frac{\sigma_B}{\sqrt{N}}, \bar{x}_B + x_\gamma \frac{\sigma_B}{\sqrt{N}} \right], \Phi(x_\gamma) = \frac{\gamma}{2}. \quad (2.3)$$

Границы доверительного интервала по правилу t-распределения находятся по формуле (2.4):

$$\hat{x}_B \in \left[\bar{x}_B - t_{(1-\gamma, N-1)} \cdot \frac{\sigma_B}{\sqrt{N}}, \bar{x}_B + t_{(1-\gamma, N-1)} \cdot \frac{\sigma_B}{\sqrt{N}} \right]. \quad (2.4)$$

Границы доверительного интервала по оценке χ^2 -распределения находится по формуле (2.5):

$$\sigma_B \in \left[\frac{\sigma_B \cdot \sqrt{N-1}}{\sqrt{\chi^2_{\left(\frac{1+\gamma}{2}, N-1\right)}}}, \frac{\sigma_B \cdot \sqrt{N-1}}{\sqrt{\chi^2_{\left(\frac{1-\gamma}{2}, N-1\right)}}} \right] \quad (2.5)$$

Выполним задачу в соответствии с заданием, в ходе выполнения воспользуемся собранным инструментарием.

2.2 Выполнение задачи

Рассмотрим пример решения на четвёртом ряде (Таблица 2.1), так как он имеет меньше элементов, с остальными рядами ход решения аналогичен.

Таблица 2.1 — Ряд из четвёртого файла

1	2	3	4	5	6	7	8	9	10
45.77	44.29	49.09	59.28	43.26	57.34	65.7	49.9	51.15	46.86

Ряд (Таблица 2.1) состоит из 10 элементов, а сумма элементов данного ряда составляет 611.1674, подставим эти данные в формулу (2.1) выборочного среднего и получим, что $\bar{x}_B = 51.265$.

Далее найдем выборочное среднеквадратическое отклонение, подставим в формулу (2.2) те же данные, что использовали при нахождении выборочного среднего, а также подставим найденное $\bar{x}_B = 51.265$. В результате вычислений, получим, что $\sigma_B = 7.293$.

Для поиска границ доверительного интервала для выборочного среднего по правилу нормального распределения воспользуемся формулой (2.3).

В результате работы функции получены границы доверительного интервала:

$$\bar{x}_B \in [46.745, 55.785]$$

Для поиска границ доверительного интервала для выборочного среднего по правилу t-распределения Стьюдента [2.1] воспользуемся формулой (2.4).

В результате подсчёта получены границы доверительного интервала:

$$\bar{x}_B \in [46.122, 56.408]$$

Для поиска границ доверительного интервала для выборочного среднеквадратического отклонения по оценке χ^2 -распределения [2.2] воспользуемся формулой (2.5).

В результате получены границы доверительного интервала:

$$\sigma_B \in [5.016, 13.314]$$

Аналогично выполним подсчеты и воспользуемся теми же формулами для подсчетов результатов для 1, 2 и 3 вещественных рядов данных реализации случайной величины.

Ниже представлены аналогичные результаты вычисления для первого ряда данных.

Среднее выборочное:

$$\bar{X}_B = 63.122$$

Среднее квадратичное:

$$\sigma_B = 4.235$$

Доверительный интервал по нормальному распределению:

$$\hat{X}_B \in [62.292, 63.952]$$

Доверительный интервал по t-распределению Стьюдента:

$$\hat{X}_B \in [62.279, 63.965]$$

Доверительный интервал среднего квадрата отклонения:

$$\hat{\sigma}_B \in [3.718, 4.919]$$

Ниже представлены аналогичные результаты вычисления для второго ряда данных.

Среднее выборочное:

$$\bar{X}_B = 70.293$$

Среднее квадратичное:

$$\sigma_B = 3.292$$

Доверительный интервал по нормальному распределению:

$$\hat{X}_B \in [68.253, 72.333]$$

Доверительный интервал по t-распределению Стьюдента:

$$\hat{X}_B \in [67.972, 72.614]$$

Доверительный интервал среднего квадрата отклонения:

$$\hat{\sigma}_B \in [2.264, 6.009]$$

Ниже представлены аналогичные результаты вычисления для третьего ряда данных.

Среднее выборочное:

$$\bar{X}_B = 49.144$$

Среднее квадратичное:

$$\sigma_B = 8.419$$

Доверительный интервал по нормальному распределению:

$$\hat{X}_B \in [47.493, 50.794]$$

Доверительный интервал по t-распределению Стьюдента:

$$\hat{X}_B \in [47.468, 50.819]$$

Доверительный интервал среднего квадрата отклонения:

$$\hat{\sigma}_B \in [7.392, 9.780]$$

Мы построили доверительные интервалы для рассчитанных точечных оценок для четырех сгенерированных рядов.

3 ИДЕНТИФИКАЦИЯ РАСПРЕДЕЛЕНИЙ

3.1 Постановка задачи

Для выполнения практического задания необходимо:

1. Скачать папку с исходными данными по ссылке. Открыть папку, соответствующую своей группе. Далее открыть папку с вариантом, совпадающим с вашим номером в списке.
2. В папке 6 файлов с данными. Данные имеют различные распределения:
 - 1 и 4 файлы - нормальное распределение;
 - 2 и 5 файлы - равномерное распределение;
 - 3 и 6 файлы - показательное распределение.
3. Методом Пирсона для каждого файла нужно проверить истинное распределение и одно ложное. При расчете теоретических частот в качестве параметров распределений брать их точечные несмещенные оценки.
4. В отчет вставить гистограммы по каждому файлу, расчетные формулы и результаты проверки распределения.
5. При проверке распределения методом анаморфоз нужно построить 3 графика для каждого из 6 файлов. Каждый график представлен в координатах соответствующей анаморфозы. Тот график, на котором достигнуто спрямление, соответствует истинному распределению. Для проверки качества спрямления необходимо построить линейный тренд (провести линейную регрессию) и показать значения коэффициента детерминации. Он должен быть близок к 1.
6. По параметрам прямой найти параметры распределения.
7. В выводах сравнить результаты, полученные двумя способами.

Оптимальное количество интервалов, на которое разбивается случайная величина рассчитывается по формуле Стерджеса (3.1):

$$n = 1 + [\log N] \quad (3.1)$$

Критерий Пирсона рассчитывается по формуле (3.2):

$$\chi^2 = \sum_{i=1}^g \frac{(n_i - n'_i)^2}{n'_i}, \quad (3.2)$$

$$n'_i = N \cdot P(X_{(i)} | \Theta) = N \cdot (P(Z_i | \Theta) - P(Z_{i-1} | \Theta)),$$

где $P(x | \Theta) = \int_{-\infty}^x p(t|\Theta) dt$ – известная функция распределения, вычисленная с параметрами $\Theta = (\theta_1, \theta_2, \dots)$, которые необходимы для расчета значения данной функции.

$P(x | \Theta)$ для нормального распределения рассчитывается по формуле (3.3):

$$p(x|\Theta) = \frac{1}{\sqrt{2n\sigma^2}} \cdot \int_{-\infty}^x \exp\left(-\frac{(t-\mu)^2}{2\sigma^2}\right) dt \quad (3.3)$$

$P(x | \Theta)$ для равномерного распределения рассчитывается по формуле (3.4):

$$P(x|\Theta) = \begin{cases} 0, x \in (-\infty, a) \\ \frac{1}{b-a} \cdot (x-a), x \in [a, b) \\ 1, \in [b, \infty) \end{cases} \quad (3.4)$$

$P(x | \Theta)$ для показательного распределения рассчитывается по формуле (3.5):

$$P(x|\theta) = \begin{cases} 1 - e^{-\lambda x}, & x \geq 0 \\ 0, & x < 0 \end{cases} \quad (3.5)$$

Анаморфоза нормального распределения может быть получена из уравнения для плотности нормального распределения путем нескольких преобразований. В итоге, получим:

$$\ln(p(x_i | \theta)) = -\ln(\sqrt{2\pi\sigma^2}) - \frac{(x - \mu)^2}{2\sigma^2} \quad (3.6)$$

Если $y(x_i) = \ln(p(x_i | \theta))$, а параметры линеаризующей прямой $a = -1/(2\sigma^2)$, $b = -\ln(\sqrt{2\pi\sigma^2})$, то представленное выше уравнение можно переписать в виде уравнения прямой для дискретного набора точек (x_i, y_i) , $i \in \overline{1, g}$, которые подчиняются нормальному распределению. Построение данных, соответствующих нормальному распределению, получает спрямление в координатах $\ln(p) \sim (x - \mu)^2$.

Анаморфоза показательного распределения может быть получена из уравнения для плотности показательного распределения путем логарифмирования правой и левой частей и итоговым преобразованием координат:

$$\ln(p(x_i | \theta)) = \ln(\lambda) - \lambda \cdot x_i \quad (3.7)$$

Если $y(x_i) = \ln(p(x_i | \theta))$, а параметры линеаризующей прямой $a = -\lambda$, $b = \ln(\lambda)$, то представленное выше уравнение можно переписать в виде уравнения прямой для дискретного набора точек (x_i, y_i) , $i \in \overline{1, g}$, которые подчиняются показательному распределению. Построение данных,

соответствующих экспоненциальному распределению, получает спрямление в координатах $\ln(p) \sim x$.

Выполним задачу в соответствии с заданием, в ходе выполнения воспользуемся собранным инструментарием.

3.2 Выполнение задачи

Рассмотрим полное выполнение задачи на примере первого файла. Для начала, разобьём диапазон на несколько интервалов, количество которых будет определяться формулой Стёрджеса (3.1).

```
data1 = pd.read_table("1.txt", header=None)
data = []
for i in range(0, data1.size):
    data.append(data1[0][i])
N = len(data)
g = 1+math.floor(math.log2(N))
g
```

Рисунок 3.1 — Код для выполнения расчёта по формуле Стёрджеса на языке Python

Таким образом, количество интервалов для выборки из первого файла равно 6.

У каждого диапазона найдём границы, середину, количество элементов из диапазона и их соотношение к общему количеству элементов выборки [3.1].

```

z = [min(data) + i*h for i in range(0, g+1)]
x = [(z[i] + z[i+1])/2 for i in range(0, g)]
n = [0 for i in range(0, g)]

print(z)
print(x)

for i in range(0, g):
    for j in range(0, N):
        if data[j] >= z[i] and data[j] < z[i+1]:
            n[i] += 1
if max(data) > z[g-1]:
    n[g-1] += 1

print(n)
p = [n[i]/N for i in range(0, g)]
print(p)

```

Рисунок 3.2 — Код для выполнения расчётов на языке Python

Соответственно, для первого файла получаем границы интервалов (для удобства представления в отчёте результаты вычислений округлены до сотых):

$[-21.55, -15.86], [-15.86, -10.17], [-10.17, -4.48],$
 $[-4.48, 1.21], [1.21, 6.89], [6.89, 12.58]$

Средины этих интервалов, соответственно:

$[-18.7, -13, -7.33, -1.68, 4.05, 9.74]$

Абсолютные частоты вхождения элементов выборки в интервалы:

$[4, 7, 7, 7, 1, 7]$

Относительные частоты вхождения элементов выборки в интервалы:

$[0.125, 0.21875, 0.21875, 0.21875, 0.03125, 0.21875]$

Воспользуемся критерием Пирсона по формуле (3.2) и проверим, является ли распределение вариационного ряда нормальным.


```

k = g-3

gamma = 0.95
x2 = 0
for i in range(0, g):
    ni = N*(ss.norm(loc=E, scale=q).cdf(z[i+1]) - ss.norm(loc=E, scale=q).cdf(z[i]))
    x2 += ((n[i] - ni)**2)/ni

x_kr = ss.chi2.ppf((1+gamma)/2, k)
print(x2, x_kr)

if x2 < x_kr:
    print('TRUE')
else:
    print("FALSE")

```

Рисунок 3.3 — Код для выполнения расчётов по критерию Пирсона для нормального распределения

Полученное значение по критерию Пирсона 13.11, когда как критическая граница 9.35. Полученное значение значительно больше критической границы области [3.2], что опровергает принадлежность выборки к нормальному распределению.




Рисунок 3.4 — Наглядная проверка соответствия первой выборки нормальному распределению

Так как истинное распределение выборки, данное в условии, не подтвердилось, проверим выборку так же на равномерное распределение по

критерию Пирсона в надежде удовлетворить требования данного задания в проверке на истинное распределение.

```
k = g-3

r = 0
for i in range(0, g):
    ni = N*(z[i+1] - z[i])/(b-a)
    r += ((n[i] - ni)**2)/ni

x_kr = ss.chi2.ppf((1+gamma)/2, k)
print(r, x_kr)

if r < x_kr:
    print('TRUE')
else:
    print("FALSE")
```

Рисунок 3.5 — Код для выполнения расчётов по критерию Пирсона для равномерного распределения

При проверке по критерию Пирсона на равномерное распределение, получим значение 5.9374999999999964, при критической границе 9.348403604496148. Полученный результат получился меньше критической границы, что доказывает, что данное распределение является равномерным.




Рисунок 3.6 — Наглядная проверка соответствия первой выборки равномерному распределению

Проведём исследование третьего ряда по критерию Пирсона, так как истинное значение распределения этого ряда должно быть показательным.

Количество интервалов, рассчитанное по формуле Стёрджеса, для выборки из третьего файла равно 6.

```
k = g-2

p1 = 0
for i in range(0, g):
    if z[i] >= 0 and z[i+1] >= 0:
        ni = N*(math.exp(-1*z[i]) - math.exp(-1*z[i+1]))
        p1 += ((n[i] - ni)**2)/ni
        #print(ni)

x_kr = ss.chi2.ppf((1+gamma)/2, k)
print(p1, x_kr)

if p1 < x_kr:
    print('TRUE')
else:
    print("FALSE")
```

Рисунок 3.7 — Код для выполнения расчётов по критерию Пирсона для равномерного распределения

При проверке по критерию Пирсона на показательное распределение, получим значение 5.9090539270217075, при критической границе 11.143286781877796. Полученный результат получился меньше критической границы, что доказывает, что данное распределение является показательным.




Рисунок 3.8 — Наглядная проверка соответствия третьей выборки показательному распределению

Также исследуем третью выборку на соответствие нормальному распределению.

Полученное значение по критерию Пирсона 80.02972281723694, когда как критическая граница 9.348403604496148. Полученное значение значительно больше критической границы области, что опровергает принадлежность выборки к нормальному распределению.




Рисунок 3.9 — Наглядная проверка соответствия третьей выборки нормальному распределению

Используя вышеописанные методики, проведём исследование второго ряда на соответствие равномерному (истинному) и нормальному распределению, четвёртого – нормальному (истинному) и равномерному распределению, пятого – равномерному (истинному) и нормальному распределению и шестого – показательному (истинному) и равномерному распределению.

Исследование второго ряда представлено ниже.

При проверке по критерию Пирсона на равномерное распределение, получим значение 1.0625000000000002, при критической границе

9.348403604496148. Полученный результат получился меньше критической границы, что доказывает, что данное распределение является равномерным.




Рисунок 3.10 — Наглядная проверка соответствия второй выборки равномерному распределению

Полученное значение по критерию Пирсона для нормального распределения 7.89167317978346, когда как критическая граница 9.348403604496148. Полученное значение значительно меньше критической границы области, так что нам следует сравнить разницу значений для равномерного и нормального распределения. Получается, $8.2859036044961478 > 1.456730424712688$, соответственно, выборка с гораздо большей вероятностью имеет равномерное распределение.




Рисунок 3.11 — Наглядная проверка соответствия первой выборки нормальному распределению

Исследование четвёртого ряда представлено ниже.

При проверке по критерию Пирсона на нормальное распределение, полученное значение по критерию Пирсона 10.338394613577549, когда как критическая граница 12.832501994030027. Полученное значение значительно больше критической границы области, что подтверждает принадлежность выборки к нормальному распределению.




Рисунок 3.12 — Наглядная проверка соответствия четвёртой выборки нормальному распределению

При проверке по критерию Пирсона на равномерное распределение, получим значение 54.4375, при критической границе 12.832501994030027. Полученный результат получился больше критической границы, что опровергает, что данное распределение является равномерным.




Рисунок 3.13 — Наглядная проверка соответствия четвёртой выборки равномерному распределению

Исследование пятого ряда представлено ниже.

При проверке по критерию Пирсона на равномерное распределение, получим значение 6.37499999999987, при критической границе 12.832501994030027. Полученный результат получился меньше критической границы, что доказывает, что данное распределение является равномерным.




Рисунок 3.14 — Наглядная проверка соответствия пятой выборки равномерному распределению

Полученное значение по критерию Пирсона для нормального распределения равно 31.67057351877361, когда как критическая граница 12.832501994030027. Полученное значение больше критической границы области, что опровергает принадлежность выборки к нормальному распределению.




Рисунок 3.15 — Наглядная проверка соответствия пятой выборки нормальному распределению

Исследование шестого ряда представлено ниже.

При проверке по критерию Пирсона на показательное распределение, получим значение 8.14960848305573, при критической границе 14.44937533544792. Полученный результат получился меньше критической границы, что доказывает, что данное распределение является показательным.




Рисунок 3.16 — Наглядная проверка соответствия шестой выборки показательному распределению

При проверке по критерию Пирсона на равномерное распределение, получим значение 157.125, при критической границе 12.832501994030027. Полученный результат получился значительно больше критической границы, что опровергает то, что данное распределение является равномерным.




Рисунок 3.17 — Наглядная проверка соответствия шестой выборки равномерному распределению

Во время исследования мы несколько раз встретились с неточностью при анализе выборки с помощью критерия Пирсона. В случае первой выборки, результаты исследования критерием Пирсона не совпали с заданным в выборке распределением. Во второй же выборке критерий Пирсона показал соответствие одновременно равномерному и нормальному распределению.

Это не удивительно, так как недостатком критерия согласия Пирсона является потеря части первоначальной информации, связанная с необходимостью группировки результатов наблюдений в интервалы и

объединения отдельных интервалов с малым числом наблюдений. Особенно это заметно при сравнительно малом объеме выборки ($n \approx 100$).

В связи с этим дополним проверку соответствия распределений, построив распределение на основе метода анаморфоз.

Для проверки распределения на основе метода анаморфоз, построим графики в спрямленных координатах, и с помощью функции `.score()` в языке программирования Python оценим коэффициент корреляции.

Проведем исследование с помощью метода анаморфоз для первого ряда. Построим график ряда в спрямленных для нормального распределения координатах (Рисунок 3.8).




Рисунок 3.18 — График первого ряда в спрямленных координатах для нормального распределения.

Посчитав коэффициент корреляции для графика, представленного выше, получаем значение 0.005360425467929808.

Построим график ряда в спрямленных для показательного распределения координатах (Рисунок 3.9).




Рисунок 3.19 — График первого ряда в спрямленных координатах для показательного распределения.

Посчитав коэффициент корреляции для графика, представленного выше, получаем значение 0.043227228863454537.

Построим график ряда в не спрямленных координатах (Рисунок 3.10).




Рисунок 3.20 — График распределения без спрямления координат.

Посчитав коэффициент корреляции для графика, представленного выше, получаем значение 0.0040816326530613845.

Наибольший коэффициент получен для координат, спрямленных для показательного распределения, и равен 0.043227228863454537. Он гораздо меньше критического значения 0.85. Получается, что распределение данного ряда не соответствует ни одному распределению, что подтверждается неоднозначным результатом исследования с помощью коэффициента Пирсона.

Проведем исследование с помощью метода анаморфоз для второго ряда. Построим график ряда в спрямленных для нормального распределения координатах (Рисунок 3.11).




Рисунок 3.21 — График в спрямленных координатах для нормального распределения.

Посчитав коэффициент корреляции для графика, представленного выше, получаем значение 0.004366843629493911.

Построим график ряда в спрямленных для показательного распределения координатах (Рисунок 3.12).




Рисунок 3.22 — График в спрямленных координатах для показательного распределения.

Посчитав коэффициент корреляции для графика, представленного выше, получаем значение 0.002837125999648582.

Построим график ряда в не спрямленных координатах (Рисунок 3.13).




Рисунок 3.23 — График распределения без спрямления координат.

Посчитав коэффициент корреляции для графика, представленного выше, получаем значение 0.0025974025974032644.

Наибольший коэффициент получен для координат, спрямленных для показательного распределения, и равен 0.004366843629493911. Он гораздо меньше критического значения 0.85. Получается, что распределение данного ряда не соответствует ни одному распределению, что подтверждается неоднозначным результатом исследования с помощью коэффициента Пирсона.

Проведем исследование с помощью метода анаморфоз для третьего ряда. Построим график ряда в спрямленных для нормального распределения координатах (Рисунок 3.14).




Рисунок 3.24 — График в спрямленных координатах для нормального распределения.

Посчитав коэффициент корреляции для графика, представленного выше, получаем значение 0.6432030799351899.

Построим график ряда в спрямленных для показательного распределения координатах (Рисунок 3.15).




Рисунок 3.25 — График в спрямленных координатах для показательного распределения.

Посчитав коэффициент корреляции для графика, представленного выше, получаем значение 0.8970764149636477.

Построим график ряда в не спрямленных координатах (Рисунок 3.16).




Рисунок 3.26 — График распределения без спрямления координат.

Посчитав коэффициент корреляции для графика, представленного выше, получаем значение 0.5888767720828789.

Наибольший коэффициент получен для координат, спрямленных для показательного распределения, и равен 0.8970764149636477. Он больше критического значения 0.85, поэтому распределение данного ряда соответствует показательному распределению. Оценим параметры выборки, взяв угол наклона линейного тренда на спрямлённых координатах:

- оцениваемый параметр $\lambda = -a = -0.02489084$;
- математическое ожидание $E[x] = 1/\lambda = 0.4894375471077578$.

Проведем исследование с помощью метода анаморфоз для четвертого ряда. Построим график ряда в спрямленных для нормального распределения координатах (Рисунок 3.17).




Рисунок 3.27 — График в спрямленных координатах для нормального распределения.

Посчитав коэффициент корреляции для графика, представленного выше, получаем значение 0.7495710884522397.

Построим график ряда в спрямленных для показательного распределения координатах (Рисунок 3.18).




Рисунок 3.28 — График в спрямленных координатах для показательного распределения.

Посчитав коэффициент корреляции для графика, представленного выше, получаем значение 0.010395948245811915.

Построим график ряда в не спрямленных координатах (Рисунок 3.19).




Рисунок 3.29 — График распределения без спрямления координат.

Посчитав коэффициент корреляции для графика, представленного выше, получаем значение 0.044698504749122736.

Наибольший коэффициент получен для координат, спрямленных для показательного распределения, и равен 0.7495710884522397. Он меньше критического значения 0.85, поэтому получается, что распределение данного ряда не соответствует ни одному распределению.

Проведем исследование с помощью метода анаморфоз для пятого ряда. Построим график ряда в спрямленных для нормального распределения координатах (Рисунок 3.20).




Рисунок 3.30 — График в спрямленных координатах для нормального распределения.

Посчитав коэффициент корреляции для графика, представленного выше, получаем значение 0.0004846989401114943.

Построим график ряда в спрямленных для показательного распределения координатах (Рисунок 3.21).




Рисунок 3.31 — График в спрямленных координатах для показательного распределения.

Посчитав коэффициент корреляции для графика, представленного выше, получаем значение 0.06589452137206364.

Построим график ряда в не спрямленных координатах (Рисунок 3.22).




Рисунок 3.32 — График распределения без спрямления координат.

Посчитав коэффициент корреляции для графика, представленного выше, получаем значение 0.05252100840336171.

Наибольший коэффициент получен для координат, спрямленных для показательного распределения, и равен 0.06589452137206364. Он значительно меньше критического значения 0.85, поэтому получается, что распределение данного ряда не соответствует ни одному распределению.

Проведем исследование с помощью метода анаморфоз для шестого ряда. Построим график ряда в спрямленных для нормального распределения координатах (Рисунок 3.23).




Рисунок 3.33 — График в спрямленных координатах для нормального распределения.

Посчитав коэффициент корреляции для графика, представленного выше, получаем значение 0.5420040635775802.

Построим график ряда в спрямленных для показательного распределения координатах (Рисунок 2.24).




Рисунок 3.34 — График в спрямленных координатах для показательного распределения

Посчитав коэффициент корреляции для графика, представленного выше, получаем значение 0.882086784824338.

Построим график ряда в не спрямленных координатах (Рисунок 3.25).




Рисунок 3.35 — График распределения без спрямления координат

Посчитав коэффициент корреляции для графика, представленного выше, получаем значение 0.7319392355191878.

Наибольший коэффициент получен для координат, спрямленных для показательного распределения, и равен 0.882086784824338. Он больше критического значения 0.85, поэтому распределение данного ряда соответствует показательному распределению. Оценим параметры выборки, взяв угол наклона линейного тренда на спрямлённых координатах:

- оцениваемый параметр $\lambda = -a = -0.3642651$
- математическое ожидание $E[x] = 1/\lambda = -0.9003250834449144$.

Используя метод Пирсона, для каждого файла было проверено одно ложное и одно истинное распределение. Из полученных значений сделан вывод о распределении рядов. Также для проверки распределения изучен метод анаморфоз. Каждый из рядов построен в спрямлённых координатах для нормального распределения, экспоненциального распределения и равномерного распределения. После спрямления рассчитаны коэффициенты детерминации и сделан вывод о распределении рядов.

4 ГЕНЕРАЦИЯ РАСПРЕДЕЛЕНИЙ

4.1 Постановка задачи

Сгенерировать выборку нормального распределения $Y \sim N(\mu, \sigma^2)$ используя определение центральной предельной теоремы. На основе $n \approx 10 \div 20$ равномерно распределенных случайных реализаций случайных величин образовать новую выборку по определению центральной предельной теоремы.

Если $Y_i \sim U(a_i, b_i)$, $i = 1, 2, \dots, n$, где Y_i — равномерно распределенная реализация случайной величины со случайными параметрами $a_i \in \mathbb{R}$, $b_i \in \mathbb{R}$, то ожидаемая нормально распределенная величина Y будет найдена по формуле (4.1):

$$Y = \sum_{i=1}^n Y_i, i = 1, 2, \dots, n \quad (4.1)$$

Для получившейся выборки построить гистограмму, визуализировать на гистограмме теоретическую плотность нормального распределения по несмещенным точечным оценкам $\hat{\mu}$, $\hat{\sigma}$ и провести тест на нормальное распределение с помощью критерия χ^2 -Пирсона и методом анаморфоз. Степени свободы рассчитывать, как $k = n - 1$.

Для генерации выборок рекомендуется пользоваться встроенными в компьютерные статистические пакеты функциями генерации равномерно распределённых случайных величин, которые задаются с помощью параметров границ интервала генерации чисел a и b .

Сгенерировать выборку χ^2 -распределения $R \sim \chi_k^2$ используя определение распределения χ^2 . На основе Z -оценок нормально распределенных случайных реализаций случайных величин $L_i \sim N(\mu_i, \sigma_i^2)$

образовать новую выборку по определению χ^2 -распределения по формуле (4.2):

$$R = \sum_{i=1}^n Z [L_i]^2, \quad Z[L_i] = \frac{L - E[L]}{\sigma[L]}, \quad L_i \sim N(\mu_i, \sigma_i^2), \quad i = 1, 2, \dots, n \quad (4.2)$$

Для получившейся выборки построить гистограмму, визуализировать на гистограмме теоретическую плотность χ^2 распределения с $k = n - 1$ степенями свободы и провести тест на χ^2 с помощью критерия χ^2 -Пирсона.

Для генерации нормально распределенных реализаций случайных величин рекомендуется пользоваться встроенными в статистические пакеты функциями для генерации значений выборки из нормального распределения, которые задаются с помощью параметров математического ожидания μ и стандартного отклонения σ^2 .

Сгенерировать выборку распределения Фишера на основе определения. На основе двух случайных реализаций Y_1, Y_2 случайных величин, распределенных по χ^2 -распределению со степенями свободы d_1, d_2 соответственно, сгенерировать выборку, распределенную по распределению Фишера $S \sim F(d_1, d_2)$ в соответствии с определением по формуле (4.3):

$$s = \frac{Y_1/d_1}{Y_2/d_2}, \quad S \sim F(d_1, d_2) \quad (4.3)$$

Для получившейся выборки построить гистограмму, визуализировать на гистограмме теоретическую плотность $F(d_1, d_2)$ распределения и провести тест на распределение Фишера с помощью критерия χ^2 -Пирсона.

Для генерации выборки фиксированного размера из распределения χ^2 рекомендуется пользоваться встроенными в статистические пакеты функциями для генерации случайных выборок из распределения χ^2 с df степенями свободы.

Реализаций $Y_1, Y_2, \dots, Y_n$ случайных величин, распределенных по стандартному нормальному распределению $Y_i \sim N(0, 1)$, $i = 1, 2, \dots, n$, сгенерировать выборку $T \sim t(n)$, распределенную по t -распределению Стьюдента с $df = n$ степенями свободы в соответствии с определением по формуле (4.4):

$$T = \frac{Y_0}{\sqrt{\frac{1}{n} \sum_{i=1}^n Y_i^2}}, Y_0 \sim N(0, 1) \quad (4.4)$$

Для получившейся выборки построить гистограмму, визуализировать на гистограмме теоретическую плотность $t(n)$, полученную через аналитическую формулу (4.5) с использованием бета-функции:

$$P_t(x|n) = \frac{1}{\sqrt{n} B\left(\frac{1}{2}, \frac{n}{2}\right)} \left(1 + \frac{x^2}{n}\right)^{-\frac{n+1}{2}}, \quad (4.5)$$

где $B(x, y) = \int_0^1 t^{x-1} (1-t)^{y-1} dt$, определённая при $\operatorname{Re} x > 0$, $\operatorname{Re} y > 0$.

Для получившейся выборки провести тест на t -распределение Стьюдента с помощью критерия χ^2 -Пирсона, используя в качестве функции вероятности распределения по формуле (4.6):

$$P_t(x|n) = \int_{-\infty}^x p_t(z|n) dz. \quad (4.6)$$

Выполним задачу в соответствии с заданием, в ходе выполнения воспользуемся собранным инструментарием.

4.2 Выполнение задачи

Сгенерируем выборку нормального распределения $Y \sim N(\mu, \sigma^2)$ используя определение центральной предельной теоремы (4.1). На основе $n = 20$ равномерно распределенных случайных реализаций случайных величин.

Для получившейся выборки построим гистограмму, визуализируем на гистограмме теоретическую плотность нормального распределения по несмещенным точечным оценкам $\hat{\mu}$, $\hat{\sigma}$ и проведем тест на нормальное распределение с помощью критерия χ^2 -Пирсона и метода анаморфоз. Степени свободы рассчитаем, как $k = n - 1$.

Сгенерируем $n = 14$ равномерно распределённых случайных величин [4.1], при этом $\min$ и $\max$ — случайно сгенерированные числа. Сложим полученные случайные величины поэлементно (см. Рисунок 4.1). Полученная случайная величина имеет нормальное распределение по ЦПТ.

```
n = 14
N = 777
a = []
b = []

for i in range(0, n):
    a.append(random()*5 - 5)
    b.append(random()*5 - 5)
    if a[i] > b[i]:
        c = b[i]
        b[i] = a[i]
        a[i] = c
    if a[i] == b[i]:
        b[i] = b[i] + 1

Y = []

for i in range(0, n):
    arr = np.random.uniform(a[i], b[i], size = N)
    Y.append(arr.tolist())
    Y_norm = []

for j in range(0, N):
    sum = 0
    for i in range(0, n):
        sum = sum + Y[i][j]
    Y_norm.append(sum)

g = 1+math.floor(math.log2(N))
print(g)
h = (max(Y_norm) - min(Y_norm))/g
plt.hist(Y_norm, bins = g)
plt.show()
```

Рисунок 4.1 — Генерация случайной выборки, соответствующей нормальному распределению.

Построим гистограмму по полученному нормальному распределению (Рисунок 4.2).




Рисунок 4.2 — Построенное нормальное распределение по ЦПТ.

Проверим полученную случайную величину на вид распределения.

Для начала произведём анализ с помощью коэффициента Пирсона. Полученное значение равно 10.915944694764713, тогда как критическое значение - 16.012764274629326. Соответственно, анализ подтверждает, что выборка имеет равномерное распределение.




Рисунок 4.3 — Наглядное сравнение распределения выборки с нормальным распределением.

Проверим с помощью метода анаморфоз (Рисунок 4.4).




Рисунок 4.4 — График случайной величины в спрямленных координатах для случайной величины.

Полученный коэффициент корреляции равен 0.9755034016176553, что больше критического значения 0.85, что значит, что случайная величина распределена нормально.

Сгенерируем выборку χ^2 -распределения $R \sim \chi_k^2$ используя определение распределения χ^2 . На основе Z-оценок нормально распределенных случайных реализаций случайных величин $L_i \sim N(\mu_i, \sigma_i^2)$ образуем новую выборку по определению χ^2 -распределения по формуле (4.2).

Для получившейся выборки построим гистограмму, визуализируем на гистограмме теоретическую плотность χ^2 распределения с $k = n - 1$ степенями свободы и проведем тест на χ^2 с помощью критерия χ^2 -Пирсона.

Сгенерируем помощью функции `gnorm(n, mean, sd)`, $n=14$ нормально распределённых величин, причем `mean` и `sd` — случайные числа. Для каждой посчитаем z-оценку. Поэлементно сложим возведённые во вторую степень z-оценки. Таким образом получим случайную величину с χ^2 распределением по определению (Рисунок 4.5).




Рисунок 4.5 — Построенное распределение χ^2 по определению.ц

Проверим соответствие нашей выборки χ^2 распределению с помощью коэффициента Пирсона. Полученное значение равно 7.217414815920186, тогда как критическое значение - 17.534546139484647. Соответственно, анализ подтверждает, что выборка имеет равномерное распределение, можно с уверенностью утверждать, что случайная величина распределена по χ^2 .

Сгенерируем выборку распределения Фишера на основе определения. На основе двух случайных реализаций Y_1, Y_2 случайных величин, распределенных по χ^2 -распределению со степенями свободы $d1, d2$ соответственно, сгенерируем выборку, распределенную по распределению Фишера $S \sim F(d1, d2)$ в соответствии с определением по формуле (4.3).

Для получившейся выборки построим гистограмму, визуализируем на гистограмме теоретическую плотность $F(d1, d2)$ распределения и проведем тест на распределение Фишера с помощью критерия χ^2 -Пирсона.

Сгенерируем с помощью функции `chisquare(n, df1/2)` две χ^2 распределённых величин, причем `df1` и `df2` — случайные числа. Получим случайную величину с распределением Фишера по определению, при этом $S \sim F(df1, df2)$ (Рисунок 4.6).




Рисунок 4.6 — Построенное распределение Фишера по определению.

Проверим по критерию χ^2 -Пирсона. При вычислении было получено значение 0.6313138337780793, критическое значение равно 16.012764274629326. Найденное значение сильно превышает критическое, соответственно, можно с уверенностью утверждать, что случайная величина имеет распределение Фишера.

Сгенерируем выборку $T \sim t(n)$, распределенную по t -распределению Стьюдента с $df = n$ степенями свободы в соответствии с определением по формуле (4.4).

Для получившейся выборки построим гистограмму, визуализируем на гистограмме теоретическую плотность $t(n)$, полученную через аналитическую формулу с использованием бета-функции по формуле (4.5).

Для получившейся выборки проведем тест на t -распределение Стьюдента с помощью критерия χ^2 -Пирсона.

Сгенерируем помощью функции `gnorm(n, mean = 0, sd = 1)`, $n = 8$ нормально распределённых величин. Воспользуемся формулой для нахождения случайной величины с t -распределением. Получим случайную величину с t -распределением по определению (Рисунок 4.7).




Рисунок 4.7 — Построенное t -распределение по определению.

Проверим по критерию χ^2 -Пирсона. При вычислении было получено значение 3.8188048951214655, критическое значение равно 17.534546139484647, случайная величина имеет t-распределение [4.2].

Нами сгенерированы четыре выборки распределённых по следующим законам: нормальное распределение, χ^2 -распределение, распределение Фишера, а также t-распределение Стьюдента. После генерации выборок нами проведены тесты на верность распределений, которые подтвердили действительность генерации заданных выборок по представленным формулам.

5 ОЦЕНКА АДЕКВАТНОСТИ МОДЕЛИ, ОЦЕНКА ДОВЕРИТЕЛЬНЫХ ИНТЕРВАЛОВ ПАРАМЕТРОВ

5.1 Постановка задачи

Для выполнения практического задания необходимо:

1. Открыть папку, соответствующую своей группе.
2. Открыть папку с вариантом, совпадающим с вашим номером в списке.

В папке 3 файла с данными.

1. 1-ый файл содержит 2 ряда данных. Первый столбец x содержит факторную переменную, второй столбец y результирующую. Для первого файла необходимо:
 - оценить коэффициент корреляции Пирсона $r(x, y)$ между двумя переменными в первом и втором столбце;
 - по шкале Чеддока оценить характеристику корреляционной связи между величинами;
 - проверить статистическую значимость коэффициента корреляции Пирсона с помощью t -статистики;
 - построить доверительный интервал для $r(x, y)$ с надежностью $\gamma = 0.95$;
 - построить линейную регрессию между столбцами, оценить значение коэффициентов линейной зависимости;
 - оценить адекватность модели с использованием критерия Фишера.
 - оценить значимость полученных коэффициентов прямой;
 - построить доверительные интервалы для полученных коэффициентов;

- оценить интервал прогноза для линейной модели на 3 значения вперед.
2. 2-ой файл содержит 4 ряда данных. Первый ряд (столбец) содержит количественную факторную переменную, следующие два — качественную факторную переменную, последний — результирующую переменную. Для второго файла данных необходимо:
- необходимо с помощью теста Чоу обосновать необходимость деления выборки по одной из качественных факторных переменных;
 - произвести разбиение и построить две линейных регрессии, оценить коэффициенты моделей.
3. 3-ий файл содержит 2 ряда данных. Для третьего файла данных необходимо:
- необходимо двумя способами (тест Спирмена и тест Гольдфельда-Квандта) определить, присутствует ли в данных гетероскедастичность;
 - построить линейную регрессию, оценить значения коэффициентов модели;
 - оценить значимость полученных коэффициентов и адекватность модели;
 - все расчеты проводить для уровня значимости $\alpha = 0.05$.

Коэффициент корреляции Пирсона $r(x, y)$ рассчитывается по формуле (5.1):

$$r(x, y) = \frac{\sum_{i=1}^m (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_{i=1}^m (x_i - \bar{x})^2 \sum_{i=1}^m (y_i - \bar{y})^2}} \quad (5.1)$$

Статистическая значимость коэффициента корреляции Пирсона рассчитывается по формуле (5.2):

$$t_r = |r| \cdot \sqrt{\frac{n-2}{1-r^2}} \quad (5.2)$$

Преобразование Фишера осуществляется по формуле (5.3):

$$z = \frac{1}{2} \ln \left(\frac{1+r}{1-r} \right) \quad (5.3)$$

Ошибка среднего рассчитывается по формуле (5.4):

$$m_z = \frac{1}{\sqrt{N-3}} \quad (5.4)$$

Доверительный интервал для z-оценке коэффициента корреляции Пирсона рассчитывается по формуле (5.5):

$$z - t(n-1)_{1-\frac{\alpha}{2}} \cdot m_z \leq z \leq z + t(n-1)_{1-\frac{\alpha}{2}} \cdot m_z \quad (5.5)$$

Подсчёт коэффициентов парной линейной регрессии производится по формулам (5.6 — 5.7):

$$a = r(x, y) \cdot \frac{\sigma_y}{\sigma_x}, b = \bar{y} - a \cdot \bar{x} \quad (5.6 — 5.7)$$

Сумма квадратов ошибок модели относительно значений результирующей переменной рассчитывается по формуле (5.8):

$$RSS = \sum_{i=1}^n (y_i - \hat{y}(x_i))^2 \quad (5.8)$$

Полная сумма квадратов рассчитывается по формуле (5.9):

$$TSS = \sum_{i=1}^n (y_i - \bar{y})^2 \quad (5.9)$$

F-статистика для оценки адекватности модели рассчитывается по формуле (5.10):

$$F = \frac{RSS / (n - 2)}{TSS / (n - 1)} \quad (5.10)$$

Оценка статистической значимости коэффициента наклона прямой осуществляется по формуле (5.11):

$$T_a = \frac{a}{m_a} \quad (5.11)$$

Коэффициент m_a рассчитывается по формуле (5.12):

$$m_a = \frac{s_{AD}}{\sigma_x \cdot \sqrt{n}} \quad (5.12)$$

Среднеквадратичное отклонение данных относительно модели регрессии рассчитывается по формуле (5.13):

$$s_{AD} = \sqrt{\frac{\sum_{i=1}^n (y_i - \hat{y}(x_i))^2}{n - 2}} \quad (5.13)$$

Оценка статистической значимости коэффициента смещения прямой осуществляется по формуле (5.14):

$$T_b = \frac{b}{m_b} \quad (5.14)$$

Коэффициент m_a рассчитывается по формуле (5.15):

$$m_b = \frac{s_{AD} \cdot \sqrt{\sum_{i=1}^n x_i^2}}{n \cdot \sigma_x} \quad (5.15)$$

Доверительный интервал для коэффициентов прямой считается по формуле (5.16 — 5.17):

$$\begin{aligned} \hat{a} &\in (a - m_a \cdot t, a + m_a \cdot t) \\ \hat{b} &\in (b - m_b \cdot t, b + m_b \cdot t) \end{aligned} \quad (5.16 — 5.17)$$

Тест Чоу для определения необходимости делить выборку по одной из качественных факторных переменных проводится по формуле (5.18):

$$F = \frac{(RSS - RSS_1 - RSS_2) / k}{(RSS_1 + RSS_2) / (n - 2k)} \quad (5.18)$$

Остатки считаются по формуле (5.19):

$$e_i = y_i - \hat{y}(x_i) \quad (5.19)$$

Коэффициент ранговой корреляции Спирмена считается по формуле (5.20):

$$r_s(e, x) = 1 - \frac{6 \sum_{i=1}^n (\text{rank}(e_i) - \text{rank}(x_i))}{n \cdot (n^2 - 1)} \quad (5.20)$$

Выполним задачу в соответствии с заданием, в ходе выполнения воспользуемся собранным инструментарием.

5.2 Выполнение задачи

Проведем исследование двух рядов. Первый столбец x содержит факторную переменную, второй столбец y результирующую.

Оценим коэффициент корреляции Пирсона $r(x, y)$ между двумя переменными в первом и втором столбце по формуле (5.1). В среднем получим -0.98521416, что обозначает хорошую отрицательную линейную корреляцию между рядами.




Рисунок 5.1 — График корреляции между рядами.

По шкале Чеддока (Таблица 5.1) оценим характеристику корреляционной связи между величинами.

Таблица 5.1 — Шкала Чеддока.

Количественная мера тесноты связи	Качественная характеристика силы связи
0.1 — 0.3	слабая
0.3 — 0.5	умеренная
0.5 — 0.7	заметная
0.7 — 0.9	высокая
0.9 — 1	весьма высокая

Значение $r = 0.985$ характеризует весьма высокую силу связи между величинами.

Проверим статистическую значимость коэффициента корреляции Пирсона с помощью t -статистики по формуле (5.2). Получим $t_r = 56.92682084483889$.

При этом критическое значение $t = 1.984467454426692$, так как посчитанное значение значительно превосходит критическая принимается гипотеза H_1 .

- H_1 : значение коэффициента линейной корреляции Пирсона значительно отличается от нуля;
- H_0 : значение коэффициента линейной корреляции Пирсона незначительно отличается от нуля.

Построим доверительный интервал для $r(x, y)$ с надежностью $\gamma = 0.95$.

Преобразуем коэффициент корреляции в z -оценку с помощью преобразования Фишера по формуле (5.3). Получим $z = 2.449905898795783$, а $m_z = 0.10153461651336192$ по формуле (5.4).

Воспользуемся подсчитанными значениями для поиска интервала по формуле (5.5) и получим доверительный интервал для $r(x, y)$.

$$r(x, y) \in [0.9779570617379464, 0.9900939956916378]$$

Построим линейную регрессию между столбцами (Рисунок 5.2), оценим значение коэффициентов линейной зависимости.




Рисунок 5.2 — Построенная линейная регрессия.

Оценим коэффициенты линейной регрессии. По формуле (5.6 — 5.7) получим $a = -2.068604269668018$, $b = -2.176205841326052$

Оценим адекватность модели с использованием критерия Фишера по формуле (5.10). Получим критерий Фишера $F = 0.029652589084669088$. Так же рассчитаем критическое значение $f(n-2, n-1) = 1.4874508733321075$. Так как рассчитанная статистика значительно меньше критического модель признается адекватной.

Оценим значимость полученных коэффициентов прямой по формулам (5.11 — 5.15). Произведя необходимые вычисления,

- $T_a = 56.92682084483959$;
- $T_b = 3.72120810212828$;
- $t = t(n-2)_{1-\frac{\alpha}{2}} = 1.984467454426692$.

Так как T_a и T_b больше критического значения, оба коэффициента (a и b) являются статистически значимыми коэффициентами.

Построим доверительные интервалы по формуле (5.16 — 5.17) для полученных коэффициентов.

$$\hat{a} \in (-2.140715759266798 - 1.9964927800692376)$$

$$\hat{b} \in (-3.336745522988804 - 1.0156661596632999)$$

Оценим интервал прогноза для линейной модели на 3 значения вперед.

Спрогнозируем значения, подставив значения x в построенную модель:

- $y_1(25.20202) = -54.30921243548468$;
- $y_2(25.40404) = -54.727112287942866$;
- $y_3(25.60606) = -55.14501214040106$.

Оценим интервал прогноза :

- $y_1 \in (\hat{y}(x) - 4.28973, \hat{y}(x) + 4.28973) = (-58.5989, -50.019)$;
- $y_2 \in (\hat{y}(x) - 4.2923, \hat{y}(x) + 4.2923) = (-59.0194, -50.4349)$;
- $y_3 \in (\hat{y}(x) - 4.2948, \hat{y}(x) + 4.2948) = (-59.4398, -50.8502)$.

Заметим, что чем дальше прогноз тем больше становится интервал прогноза.

Проведем исследование второго набора данных. Он содержит 4 ряда данных. Первый ряд содержит количественную факторную переменную, следующие два — качественную факторную переменную, последний — результирующую переменную.

Построим графики зависимость y от x (см. Рисунок 5.3).




Рисунок 5.3 — Визуализация данных.

Необходимо с помощью теста Чоу [5.1] обосновать необходимость деления выборки по одной из качественных факторных переменных. Для этого рассчитаем коэффициент F по формуле (5.18):

Рассчитаем элементы для подсчёта F -статистики для первой категориальной переменной:

- $RSS = 103512.9700019589$ — RSS для общей модели;
- $RSS_1 = 26.920606031841647$ — RSS для модели где категориальная переменная равна 0;
- $RSS_2 = 523.3921636131192$ — RSS для модели где категориальная переменная равна 1;
- $k = 2$ — количество элементов построенной модели;
- $n = 200$ — количество строк в оцениваемой таблице.

Тогда $F = 18335.646500219576$, при этом критическое значение $f(k, n-2k) = 3.759186550251152$. Рассчитанная F -статистика значительно больше критического значения, поэтому принимается гипотеза о том, что следует строить отдельные модели в соответствии с данной категориальной переменной.

Рассчитаем элементы для подсчёта F -статистики для второй категориальной переменной:

- $RSS = 103512.9700019589$ — RSS для общей модели;
- $RSS_1 = 45136.24559477505$ — RSS для модели где категориальная переменная равна 0;
- $RSS_2 = 57803.56366097967$ — RSS для модели где категориальная переменная равна 1;
- $k = 2$ — количество элементов построенной модели;
- $n = 200$ — количество строк в оцениваемой таблице.

Тогда $F = 0.5456562775287073$, при этом критическое значение $f(k, n-2k) = 3.759186550251152$. Рассчитанная F -статистика значительно меньше критического значения, поэтому принимается гипотеза о том, что следует строить общую модель.

На основе предыдущего анализа, можно сделать вывод, что имеет смысл разбивать выборку относительно первой качественной факторной переменной. Произведем разбиение и построим две линейных регрессии, оценив коэффициенты моделей (Рисунок 5.5).




Рисунок 5.5 — Визуализация построенных моделей.

Построим первую модель, где категориальная переменная равна 0, $a = -0.5640763300165246$, $b = 0.8883726286302522$. Построим вторую модель, где категориальная переменная равна 1, $a = 2.318808616810883$, $b = -0.2049038611129106$ (Рисунок 5.6, Рисунок 5.7)




Рисунок 5.6 — Визуализация построенных моделей.




Рисунок 5.7 — Визуализация разбиения модели.

Исследуем 3 набор данных, содержащий 2 ряда данных. Необходимо двумя способами (тест Спирмена и тест Гольдфельда-Квандта) определить, присутствует ли в данных гетероскедастичность.

Воспользуемся тестом Спирмена построим линейную регрессию и посчитаем остатки по формуле (5.19).

Отранжируем рассчитанные остатки, а также отранжируем переменную, относительно которой ожидается гетероскедастичность. Произведем вычисления коэффициента ранговой корреляции Спирмена по формуле (5.20). Получим $R_s = 0.026867347536632225$ и критическое значение - 1.959963984540054.

Рассчитанная статистика меньше чем критическое значение, поэтому принимаем гипотезу об отсутствии гетероскедастичности.

Воспользуемся тестом Гольдфельда-Квандта.

Отсортируем выборку по первой переменной и возьмем по $m_1 = m_2 = \lfloor 0.4 * n \rfloor$ записей с каждой стороны. Тогда можем рассчитать F -статистику: для $n = 100$, $m_1 = m_2 = 40$, $k = 1$.

Воспользовавшись встроенной функции языка R, получим $F = 9.343230907997683$, при критическом значении $F(39, 39)_{1-0.05/2} \approx 1.9421160838960818$.

Расчётная статистика намного больше критического значения распределения Фишера, что говорит о принятии гипотезы о наличии гетероскедастичности в данной зависимости.

Необходимо построить линейную регрессию, оценить значения коэффициентов модели (Рисунок 5.6).




Рисунок 5.6 — Визуализация построенной модели.

Оценим коэффициенты линейной регрессии $a = 1.8985646827572935, b = -8.788548039838648$.

Оценим значимость полученных коэффициентов и адекватность модели.

Оценим адекватность модели с использованием критерия Фишера по формуле (5.10). Получим:

- $RSS = 9155.65683565978$;
- $TSS = 85543.4159299567$;
- $F = 9.343230907997683$.

Так же рассчитаем критическое значение $f(n-2, n-1) = 1.9421160838960818$. Так как рассчитанная статистика больше критического, модель можно признать адекватной [5.2].

Оценим значимость полученных коэффициентов прямой по формуле (5.11 — 5.15). Получим:

- $T_a = 3.1502536666620755$;
- $T_b = -0.9061116851979744$;
- $t = t(n-2)_{1-\frac{\alpha}{2}} = 1.984467454426692$;

Так как Tb меньше критического значения, b — статистически не значимый коэффициент. Ta больше критического значения, a — статистически значимый коэффициент.

Мы оценили коэффициент корреляции между двумя рядами данных, после подсчета оценили характеристику корреляционной связи между величинами, проверили статистическую значимость найденного коэффициента корреляции, а также построили доверительный интервал для коэффициента Пирсона. Мы изучили аппарат для определения необходимости деления выборки по одной из качественной переменной. Воспользовавшись тестом Чоу, произвели разбиение выборки по одной из качественной переменной. Оценили коэффициенты построенной модели. Изучили способы определения наличия гетероскедастичности в данных.

6 СГЛАЖИВАНИЕ ВРЕМЕННЫХ РЯДОВ

6.1 Постановка задачи

Для выполнения практического задания необходимо:

- открыть папку, соответствующую своей группе;
- открыть папку с вариантом, совпадающим с вашим номером в списке.

В папке два файла, которые содержат разные временные ряды. В первом файле находится ряд с синусоидальным трендом. Во втором — с линейным.

Необходимо выделить тренд используя 4 метода:

1. простое скользящее среднее (SMA);
2. взвешенное скользящее среднее (WMA) особо типа;
3. экспоненциальное сглаживание (EMA);
4. двойное экспоненциальное сглаживание (DEMA).

Каждый метод требует подбора некоторых параметров:

1. SMA и WMA — размер окна, EMA — параметр сглаживания A , DEMA — параметр сглаживания вокруг тренда A и параметр сглаживания самого тренда B .
2. Необходимо подобрать оптимальные значения соответствующих параметров, используя Q-статистику Льюнг-Бокса при $m = 5$. Оптимальными параметрами будем считать те, что минимизируют приведенную статистику.
3. В качестве размеров окна $w = 2 * m + 1$ перебрать значения $m = 3, 5, 7, 9$; в качестве параметров сглаживания: $\alpha, \gamma = 0.1, 0.2, \dots, 0.9$. Обратите внимание, что метод DEMA двухпараметрический, что требует выбрать оптимальную комбинацию сразу двух параметров α, γ .

4. После подбора оптимальных параметров провести тест Дарбина-Уотсона ($m = 1, \alpha = 0.95$) на данных после исключения выделенного тренда для каждого метода и каждого ряда.
5. В отчете изобразить графики исходных данных, графики трендов при оптимальных параметрах у каждого метода для каждого ряда, расчетные формулы, а также результаты тестов Дарбина-Уотсона.

Размер окна определяется по формуле (6.1):

$$\omega = 2 \cdot m + 1 \quad (6.1)$$

Веса для SMA рассчитываются по формуле (6.2):

$$w_i = \frac{1}{2 \cdot m + 1} \quad (6.2)$$

Экспоненциальная весовая функция (6.3) используется для определения весов в WMA:

$$w_i = \frac{e^{-\varepsilon \cdot |-i|}}{\sum_{j=-m}^m e^{-\varepsilon \cdot |j|}} \quad (6.3)$$

Модель скользящего среднего определяется по формуле (6.4):

$$\tilde{y}_t = \sum_{i=-m}^m w_i \cdot y_{t+i} \quad (6.4)$$

Модель экспоненциального сглаживания определяется рекурсивной формулой (6.5):

$$\tilde{y}_t = \begin{cases} y_t, & t = 1 \\ \tilde{y}_{t-1} + \alpha \cdot (y_t - \tilde{y}_{t-1}), & t > 1 \end{cases} \quad (6.5)$$

Модель двойного экспоненциального сглаживания определяется рекурсивной формулой (6.6):

$$\begin{aligned}\tilde{y}_t &= \alpha \cdot y_t + (1 - \alpha) \cdot (\tilde{y}_{t-1} + b_{t-1}) \\ b_t &= \gamma \cdot (\tilde{y}_t - \tilde{y}_{t-1}) + (1 + \gamma) \cdot b_{t-1} \\ \tilde{y}_1 &= y_1, b_1 = y_2 - y_1\end{aligned}\tag{6.6}$$

Для проверки отсутствия автокорреляции остатков используется Q-статистика Льюнг-Бокса, которая вычисляется по формуле (6.7):

$$Q = n \cdot (n - 2) \cdot \sum_{k=1}^m \frac{r(k)^2}{n - k}\tag{6.7}$$

Критерий Дарбина-Уотсона рассчитывается по формуле (6.8):

$$d = \frac{\sum_{t=2}^n (e_t - e_{t-1})^2}{\sum_{t=1}^n e_t^2}\tag{6.8}$$

Выполним задачу в соответствии с заданием, в ходе выполнения воспользуемся собранным инструментарием.

6.2 Выполнение задачи

Построим графики временных рядов, тренд которых будет выделен в работе. Построим первый временной ряд с не линейным трендом (Рисунок 6.1).




Рисунок 6.1 — График первого временного ряда.

Построим второй временной ряд с линейным трендом (Рисунок 6.2).




Рисунок 6.2 — График второго временного ряда.

Реализуем метод сглаживания SMA по формуле (6.4) для этого необходимо выбрать параметр m — количество членов ряда в сумме по одной стороне от центрального значения. Для этого произведём

минимизацию Q-статистики для $m \in 3, 5, 7, 9$. Для первого ряда Q-статистика минимальна при $m = 3$, для второго ряда - при $m = 7$.

Возьмем $m = 3$ для первого ряда и $m = 7$ для второго ряда. Также необходимо рассчитать веса. SMA — простое скользящее среднее и имеет одинаковые веса для всех значений в окне. Размер окна определяется по формуле (6.1), веса для элементов окна — по формуле (6.2).

Реализуем сглаживание по полученным параметрам. Построим первый сглаженный ряд (Рисунок 6.3).




Рисунок 6.3 — Сглаживание первого временного ряда методом SMA.

Построим второй сглаженный ряд (Рисунок 6.4).




Рисунок 6.4 — Сглаживание второго временного ряда методом SMA.

Проверим Q-статистику Льюнг-Бокса по формуле (6.7), тем самым узнав автокоррелируют ли остатки на m количестве лагов, чтобы проверить являются ли они случайными.

Значение Q-статистики для первого ряда равно 88.62368731142485, для второго ряда равно 9.111602468688764. Q-статистика распределена по χ^2 , а критическое значение равно 12.832. Для первого ряда остатки автокоррелируют, для второго ряда остатки являются случайной величиной. Для обоих рядов m было выбрано оптимальным [6.1], то есть при таком m Q-статистика минимальна, при переборе $m = 3, 5, 7, 9$.

Также проведём тест Дарбина-Уотсона по формуле (6.8) ($m = 1$, $\alpha = 0.95$). Для того чтобы определить автокорреляцию первого порядка для случайной составляющей временного ряда. Значение для первого ряда равно 0.9948872559304771, для второго ряда 1.6814467707241143, при этом критическое значение 5.024. Первое значение не превышает критическое значение, следовательно, первый ряд автокоррелирует, чего нельзя сказать про второй ряд.

Аналогично вышеописанной реализации метода SMA, реализуем метод сглаживания WMA по формуле, для этого необходимо выбрать параметр m

— количество членов ряда в сумме по одной стороне от центрального значения. Возьмем $m = 3$ для первого ряда и $m = 7$ для второго ряда.




Рисунок 6.5 — Сглаживание первого временного ряда методом WMA.

Построим второй сглаженный ряд (Рисунок 6.6).




Рисунок 6.6 — Сглаживание второго временного ряда методом WMA.

Значение Q-статистики для первого ряда равно 82.02759257001826, для второго ряда равно 6.67186906700688. Q-статистика распределена по χ^2 .

а критическое значение равно 12.832. Для первого ряда остатки автокоррелируют, для второго ряда остатки являются случайной величиной.

Также проведём тест Дарбина-Уотсона по формуле (6.8) ($m = 1$, $a = 0.95$). Для того чтобы определить автокорреляцию первого порядка для случайной составляющей временного ряда. Значение для первого ряда равно 1.0394441656735782, для второго ряда 1.5727677303021212, при этом критическое значение 5.024. Оба значения не превышают критическое из чего можно сделать вывод, что для них выделенная случайная величина автокоррелирует.

Реализуем метод сглаживания ЕМА по формуле для этого необходимо выбрать параметр a — параметр сглаживания. Возьмем $a = 0.1$ для первого ряда и $a = 0.7$ для второго ряда. ЕМА — позволяет рекурсивно оценить новое значение сглаженного ряда по исходным данным по формуле (6.5).

Реализуем сглаживание по полученным параметрам. Построим первый сглаженный ряд (Рисунок 6.7).




Рисунок 6.7 — Сглаживание первого временного ряда методом ЕМА.

Построим второй сглаженный ряд (Рисунок 6.8).




Рисунок 6.8 — Сглаживание второго временного ряда методом ЕМА.

Проверим Q-статистику Льюнг-Бокса по формуле (6.7) при $m = 5$, тем самым узнав автокоррелируют ли остатки на m количестве лагов, чтобы проверить являются ли они случайными. Значение Q-статистики для первого ряда равно 48.64591969955467, для второго ряда равно 5.575496312829345. Q-статистика распределена по χ^2 , а критическое значение равно 12.832. Для первого ряда остатки не являются случайной величиной, для второго ряда остатки являются случайной величиной. Для обоих рядов α было выбрано оптимальным, то есть при таком α — Q-статистика минимальна, при переборе $\alpha = 0.1, 0.2, 0.3, 0.4, 0.5, 0.6, 0.7, 0.8, 0.9$.

Также проведём тест Дарбина-Уотсона по формуле (6.8) ($m = 1$, $\alpha = 0.95$). Для того чтобы определить автокорреляцию первого порядка для случайной составляющей временного ряда. Значение для первого ряда равно 1.505117162295848, для второго ряда 1.0347984928672826, при этом критическое значение 5.024. Оба значения не превышают критическое из чего можно сделать вывод, что выделенная случайная величина автокоррелирует.

Реализуем метод сглаживания DEMA для этого необходимо выбрать параметр a — сглаживания вокруг тренда и b — параметр сглаживания

самого тренда. Возьмем $a = 0.9$, $b = 0.9$, для первого ряда и $a = 0.2$, $b = 0.1$ для второго ряда, соответственно. ДEMA — двойное экспоненциальное сглаживание позволяет рекурсивно оценить новое значение сглаженного ряда по исходным данным по формуле (6.6).

Реализуем сглаживание по полученным параметрам. Построим первый сглаженный ряд (Рисунок 6.9).




Рисунок 6.9 — Сглаживание первого временного ряда методом ДEMA.

Построим второй сглаженный ряд (Рисунок 6.10).




Рисунок 6.10 — Сглаживание второго временного ряда методом ДEMA.

Проверим Q-статистику Льюнг-Бокса по формуле (6.7) при $m = 5$, тем самым узнав автокоррелируют ли остатки на m количестве лагов, чтобы проверить являются ли они случайными. Значение Q-статистики для первого ряда равно 17.30037254246672, для второго ряда равно 12.586. Q-статистика распределена по χ^2 , а критическое значение равно 12.832. Для первого ряда остатки автокоррелируют, для второго ряда остатки являются случайной величиной. Для обоих рядов a и b были выбраны оптимальными, то есть при таком a и b Q-статистика минимальна, при переборе $a, b = 0.1, 0.2, 0.3, 0.4, 0.5, 0.6, 0.7, 0.8, 0.9$.

Также проведём тест Дарбина-Уотсона по формуле (6.8) ($m = 1, a = 0.95$). Для того чтобы определить автокорреляцию первого порядка для случайной составляющей временного ряда. Значение для первого ряда равно 2.1549617516156343, для второго ряда 2.459468, при этом критическое значение 5.024. Оба значения не превышают критическое из чего можно сделать вывод, что выделенная случайная величина автокоррелирует.

Мы изучили методы для выделения тренда. Нами были рассмотрены два метода, скользящего среднего, которые отличаются способами подсчета весов. Также были рассмотрены два метода экспоненциального сглаживания. Для каждого из методов подобрали необходимые параметры, провели тест Дарбина-Уотсона и тест Льюнг-Бокса для определения коорреляции.

ЗАКЛЮЧЕНИЕ

В ходе выполнения курсовой работы мною был рассмотрен теоретический аспект расчета статистических параметров, построения доверительных интервалов точечных оценок, идентификации распределений, генерации распределений, оценок адекватности модели, сглаживания временных рядов, а также были построены регрессионные модели и сделаны статистические выводы о различных объектах исследования.

Для изучения предмета статистики разработаны и применяются специфические приемы, которые в совокупности образуют методологию статистики. Понятие статистики можно определить как совокупность приемов, применяемых ею для познания своего предмета. Сама статистика также выступает методом познания и для других общественных наук.

В данной курсовой работе были решены такие статистические задачи, как:

- расчет статистических параметров;
- построение доверительного интервала точечных оценок;
- идентификация распределений;
- генерация распределений;
- оценка адекватности моделей;
- сглаживание временных рядов.

Для решения некоторых задач использовался язык программирования Python в среде разработки Google Collaboratory для удобства и точности подсчета и построения графиков как наглядных примеров.

Цель курсовой работы — применение знаний, полученных на курсе «Прикладные задачи математической статистики» — достигнута.

СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ

1 РАСЧЕТ СТАТИСТИЧЕСКИХ ПАРАМЕТРОВ

- 1.1 С. Е. Демин, Е. Л. Демина, М-во образования и науки РФ, ФГАОУ ВО «УрФУ им. первого Президента России Б.Н.Ельцина», Нижнетагил. технол. ин-т (фил.). — Нижний Тагил : НТИ (филиал) УрФУ, 2016. – 284 с.
- 1.2 О.И. Хайруллина, О.В. Баянова; Министерство сельского хозяйства Российской Федерации, федеральное государственное бюджетное образовательное учреждение высшего образования «Пермский аграрно-технологический университет имени академика Д.Н. Прянишникова». — Пермь : ИПЦ «Прокрость», 2019 — 176 с.

2 ДОВЕРИТЕЛЬНЫЕ ИНТЕРВАЛЫ ТОЧЕЧНЫХ ОЦЕНОК

- 2.1 К. О. Кизбикенов. — Барнаул : АлтГПУ, 2017 — 115 с.
Вероятностные разделы математики / Под ред. Максимова Ю.Д. — Спб.: «Иван Фёдоров», 2001. — С. 400. — 592 с.
- 2.2 Карасёва Л. А. Статистика // Всемирная история экономической мысли: В 6 томах / Гл. ред. В. Н. Черковец. — М.: Мысль, 1987. — Т. I. От зарождения экономической мысли до первых теоретических систем политической жизни. — С. 484 — 494. — 606 с. — 20 000 экз. — ISBN 5-244-00038-1.

3 ИДЕНТИФИКАТОР РАСПРЕДЕЛЕНИЙ

- 3.1 Миклашевский И. Н. Статистика теоретическая // Энциклопедический словарь Брокгауза и Ефрона : в 86 т. (82 т. и 4 доп.). — СПб., 1890—1907.
- 3.2 Норман Дрейпер, Гарри Смит. Прикладной регрессионный анализ. Множественная регрессия — 3-е изд. — М.: «Диалектика», 2007. — С. 912. — ISBN 0-471-17082-8.

4 ГЕНЕРАЦИЯ РАСПРЕДЕЛЕНИЙ

- 4.1 Орлов А. И. Прикладная статистика. Учебник. — М.: Экзамен, 2006. — 671 с.
- 4.2 Дарелл Хафф. Как лгать при помощи статистики. — М.: Альпина Паблишер, 2015. — 163 с. — ISBN 978-5-9614-5212-9.

5 ОЦЕНКА АДЕКВАТНОСТИ МОДЕЛИ, ОЦЕНКА ДОВЕРИТЕЛЬНЫХ ИНТЕРВАЛОВ ПАРАМЕТРОВ

- 5.1 Глинский В. В., Ионин В. Г. Статистический анализ. — М.: Инфра-М, 2002. — 241 с. — (Высшее образование). — 5000 экз. — ISBN 5-16-001293-1.
- 5.2 Кендалл М., Стьюарт А. Многомерный статистический анализ и временные ряды. — М.: Наука, 1976. — 736 с.

6 СГЛАЖИВАНИЕ ВРЕМЕННЫХ РЯДОВ

- 6.1 White C. Unkind cuts at statisticians (англ.) // The American Statistician. — 1964. — Vol. 18, no. 5. — P. 15—17.