



МИНОБРНАУКИ РОССИИ

Федеральное государственное бюджетное образовательное учреждение
высшего образования

«МИРЭА – Российский технологический университет»

РТУ МИРЭА

Институт информационных технологий

Кафедра прикладной математики

КУРСОВАЯ РАБОТА

по дисциплине Технологии организации, обработки и хранения статистических данных
(наименование дисциплины)

Тема курсовой работы Анализ экологических факторов на примере кластерного анализа
качества воздуха в Мадриде за 2015 год

Студент группы ИМБО-01-20 Черных Анастасия Николаевна

(учебная группа, фамилия, имя отчество, студента)

_____ (подпись студента)

Руководитель курсовой работы доцент, к.п.н, Митина О.А.

(должность, звание, ученая степень)

_____ (подпись руководителя)

Рецензент (при наличии) ассистент, Митин М.П.

(должность, звание, ученая степень)

_____ (подпись рецензента)

Работа представлена к защите « ____ » _____ 2021г.

Допущен к защите « ____ » _____ 2021г.

Москва 2021 г



МИНОБРНАУКИ РОССИИ

Федеральное государственное бюджетное образовательное учреждение
высшего образования

«МИРЭА – Российский технологический университет»

РТУ МИРЭА

Институт информационных технологий

Кафедра прикладной математики

Утверждаю

Заведующий кафедрой _____

Подпись

Держинский Роман Игоревич

ФИО

«___» _____ 2021г.

ЗАДАНИЕ

на выполнение курсовой работы по дисциплине

« Технологии организации, обработки и хранения статистических данных »

Студент Черных Анастасия Николаевна Группа ИМБО-01-20

Тема: Анализ экологических факторов на примере кластерного анализа качества воздуха в Мадриде за 2015 год

Исходные данные: платформа Loginom

Перечень вопросов, подлежащих разработке, и обязательного графического материала: предобработка данных, кластеризация данных, обучение грамотному оформлению сопутствующей документации, использование знаний математической статистики с использованием современных средств обработки данных, изучение научной и методической литературы по проблеме кластеризации данных и анализа экологической обстановки

Срок представления к защите курсовой работы: до «___» _____ 2021г.

Задание на курсовую работу выдал

Подпись руководителя

(Митина О. А.)

Ф.И.О. руководителя

Задание на курсовую работу получил

«___» _____ 2021г.

Подпись обучающегося

(Черных А.Н.)

Ф.И.О. обучающегося

Москва 2021г

ОТЗЫВ

на курсовую работу

по дисциплине «Технологии организации, обработки и хранения статистических данных»

Студент Черных А.Н.
(ФИО студента)

ИМБО-01-20
(Группа)

Характеристика курсовой работы

Критерий	Да	Нет	Не полностью
1. Соответствие содержания курсовой работы указанной теме			
2. Соответствие курсовой работы заданию			
3. Соответствие рекомендациям по оформлению текста, таблиц, рисунков и пр.			
4. Полнота выполнения всех пунктов задания			
5. Логичность и системность содержания курсовой работы			
6. Отсутствие фактических грубых ошибок			

Замечаний:

Рекомендуемая оценка:

Подпись руководителя

ФИО руководителя

СОДЕРЖАНИЕ

ВВЕДЕНИЕ	5
ТЕОРЕТИЧЕСКАЯ ЧАСТЬ.....	6
Анализ качества	6
Кластерный анализ.....	8
Анализ экологических воздействий	11
ПРАКТИЧЕСКАЯ ЧАСТЬ	15
Предобработка данных	15
Кластеризация	18
Визуализация.....	20
ЗАКЛЮЧЕНИЕ	22
СПИСОК ИСПОЛЬЗУЕМОЙ ЛИТЕРАТУРЫ	24
ПРИЛОЖЕНИЕ	25

ВВЕДЕНИЕ

Здоровье человека зависит от многих факторов, одним из которых является экологическая обстановка. Экологическая обстановка формируется под влиянием двух противоречивых тенденций: использования окружающей среды и экологизации, при которой на основе научных исследований в области экологии разработаны методические подходы к оценке воздействия загрязнения окружающей среды на здоровье человека, животный и растительный мир, объекты экономики, жизнедеятельности.

Оценка качества воздуха позволяет определить степень загрязнения, выявить его причину и реализовать методы для улучшения ситуации. Поэтому данная тема курсовой работы является актуальной для сферы мониторинга экологической обстановки различных регионов.

Цель курсовой работы – провести кластерный анализ по качеству воздуха на примере воздуха в Мадриде за 2015 год.

Задачи, решаемые в данной курсовой работе:

- изучение научной и методической литературы по проблеме кластеризации данных, качественного анализа и анализа экологической обстановки;
- ознакомление с нормами содержания химических соединений в воздухе;
- предобработка данных;
- использование знаний математической статистики с использованием современных средств обработки данных: аналитической платформы Loginom, функционального инструмента визуализации и анализа данных Microsoft Excel;
- кластеризация данных;
- обучение грамотному оформлению сопутствующей документации.

ТЕОРЕТИЧЕСКАЯ ЧАСТЬ

Анализ качества

Главная задача анализа качества – это определить динамику показателей, определить уровень их соответствия плану, причины изменения этих показателей, а затем оценить данные с позиции уровня качества, который достигнут и которого можно достичь. Применение статистических методов анализа качества должно в обязательном порядке предшествовать внедрению статистических методов регулирования технологических процессов.

В статистике рассчитывают индивидуальные и общие коэффициенты, например индивидуальный коэффициент сортности определяется по каждой товарной или ассортиментной подгруппе. Текущий контроль качества продукции осуществляется в процессе ее производства. Для этого предназначены специальные процедуры – методы контроля качества. Особенно интенсивно методы контроля качества используются в США, Германии, Японии. Методом контроля, представленным в данной работе, является обработка среднесуточных показателей.

Общий же подход к текущему контролю качества заключается в следующем: в процессе производства из произведенной продукции или поступающего сырья проводится отбор выборок изделий заданного объема. После этого строятся диаграммы средних значений и изменчивости выборочных значений плановых спецификаций в этих выборках и рассматривается степень их близости к плановым значениям. Если диаграммы показывают наличие тренда выборочных значений или выборочные значения оказываются вне заданных пределов, то считается, что процесс вышел из-под контроля, и предпринимаются необходимые действия для того, чтобы найти причину разладки.

Процедуры выборочного контроля используются в случае, когда нужно решить, удовлетворяет ли определенным спецификациям партия изделий, не

изучая при этом все изделия. Такие процедуры называют статистическим приемочным контролем. Преимущество выборочного контроля — изучение только выборки, а не целой партии требует меньше времени и финансовых затрат. Однако в случае экологического анализа такой метод контроля категорически неприемлем, так как не позволяет оценить полную картину.

При анализе качества также часто рассматривается график размахов. Размах — это разность между максимальным и минимальным значением выборки. Прагматическая ценность этой характеристики — в том, что она служит мерой изменчивости. По расположению точек на графике размахов принимают решение о случайности или систематичности отклонения в качестве.

Потенциальная пригодность — показатель пригодности производственного процесса, определяется как отношение размаха допуска к размаху процесса.

Обобщающими показателями качества продукции принято считать:

- удельный вес новой продукции;
- удельный вес инновационной продукции;
- удельный вес сертифицированной продукции;
- удельный вес экспортируемой продукции;
- коэффициент сортности продукции.

Уровень потребительского качества конкретного вида продукции определяется элементарно, если качество характеризуется одним параметром. Если же продукция характеризуется несколькими параметрами качества, то для сводной оценки динамики уровня качества академик В. А. Трапезников предложил интегральный коэффициент качества, вычисляемый как произведение относительных величин изменения каждого контролируемого параметра.

Также результате проверки качества продукции может быть обнаружен брак. Это означает, что продукция не соответствует ГОСТу, ТУ и другим требованиям, изложенным в документах аналогичного характера. Брак различают по характеру (исправимый и неисправимый), по местам появления

(внутренний и внешний) и по причинам (недостатки в организации производства, нарушения технологической дисциплины, недостаточная квалификация персонала, неисправность оборудования и др.).

Для характеристики брака и потерь от брака рассчитывают следующие показатели:

1. абсолютный размер брака в денежном выражении;
2. абсолютный размер потерь от брака;
3. процент брака;
4. процент потерь от брака.

Абсолютный размер брака представляет собой сумму затрат, связанных с производством брака и его исправлением. Он может быть уменьшен на суммы, взысканные с виновников брака и на суммы, полученные от реализации брака. Эта величина и составит абсолютный размер потерь от брака. Полученные показатели можно сравнивать с производственной себестоимостью продукции и определять размер брака в процентах и размер потерь от брака в процентах. В экологическом анализе невозможно выразить размер брака в денежном выражении, однако можно указать процентное содержание.

Кластерный анализ

Кластерный анализ (от англ. cluster analysis) – совокупность многомерных статистических методов классификации объектов по характеризующим их признакам, разделение совокупности объектов на однородные группы, близкие по определяющим критериям, выделение объектов определенной группы. Он предназначен для разбиения совокупности объектов на однородные группы, которые также называют кластерами или классами.

Кластер – это группы объектов, выделенные в результате кластерного анализа на основе заданной меры сходства или различий между объектами. Объект – это конкретные предметы исследования, которые необходимо классифицировать. Объектами при классификации выступают, как правило,

наблюдения. Например, потребители продукции, страны или регионы, товары и т.п.




Рисунок 1 – Визуальное представление кластеров

Классификация объектов в многомерном кластерном анализе происходит по нескольким признакам одновременно. Это могут быть как количественные, так и категориальные переменные в зависимости от метода кластерного анализа. Главная цель кластерного анализа – нахождение групп схожих объектов в выборке.

Существует два вида многомерных статистических методов кластерного анализа:

- иерархические методы (агломеративные и дивизимные);
- неиерархические (метод k -средних, двухэтапный кластерный анализ, метод ближайших соседей).

Наиболее часто используемые из них - это оба метода иерархического кластерного анализа и кластеризация методом k -средних. Сущность этих иерархического кластерного анализа заключается в том, что на первом шаге каждый объект рассматривается как отдельный кластер. Процесс объединения кластеров происходит последовательно: на основании матрицы расстояний или матрицы сходства объединяются наиболее близкие объекты. Если матрица сходства первоначально имеет размерность $n \times n$, то полностью процесс кластеризации завершается за $n - 1$ шагов, в итоге все объекты будут объединены в один кластер.

В общем виде алгоритм иерархического кластерного анализа можно представить в виде последовательности процедур:

1. Значения исходных переменных нормируются.
2. Рассчитывается матрица расстояний или матрица мер близости.
3. Находится пара самых близких кластеров. По выбранному алгоритму объединяются эти два кластера. Новому кластеру присваивается меньший из номеров объединяемых кластеров.
4. Пункты 2, 3 и 4 повторяются до тех пор, пока все объекты не будут объединены в один кластер или до достижения заданного "порога" близости.

Иерархические методы объединения, хотя и точны, но трудоёмки: на каждом шаге необходимо выстраивать дистанционную матрицу для всех текущих кластеров. Расчётное время растёт пропорционально третьей степени количества наблюдений, что при наличии нескольких тысяч наблюдений может утомить и серьёзные вычислительные машины.

В то же время, метод кластеризации k -средних позволяет разделить объекты на заданное число кластеров в соответствии с критерием, представляющим собой статистику Фишера: отношение межкластерной дисперсии к внутрикластерной. В результате разделение осуществляется так, чтобы изменчивость переменных внутри кластеров была малой, между кластерами - большой. Иными словами, объекты, входящие в один и тот же кластер, были расположены в пространстве переменных близко, а входящие в разные кластеры - далеко друг от друга.

В отличие от иерархических методов метод K -средних не рассматривает все возможные варианты разбиения на заданное число кластеров. Начиная работу с какого-то, как правило, произвольного варианта, метод последовательно меняет разбиение до тех пор, пока критерий оптимизации не перестаёт меняться. В силу этого, если на пути алгоритма встретился не глобальный максимум критерия, а лишь некоторый из локальных, метод может прекратить свою работу, не дойдя до глобально оптимального разбиения.

Поэтому при его использовании очень важны начальные условия. Другая же проблема при работе с данным методом состоит в том, что исследователю приходится из каких-то соображений задавать число кластеров. При оценке экологии важно учитывать наиболее широкий спектр неудовлетворительных состояний, поэтому мы применим метод k-средних с тремя кластерами, один из которых будет включать в себя наихудшие, с экологической точки зрения, дни.

Если рассматривать глобально, то можно отметить, что кластеризация является одной из фундаментальных задач в области анализа данных и Data Mining. Список прикладных областей, где она применяется, широк: сегментация изображений, маркетинг, борьба с мошенничеством, прогнозирование, анализ текстов и многие другие. Кластерный анализ хорошо зарекомендовал себя во всех сферах жизнедеятельности человека. Прелесть данного метода - он работает даже тогда, когда данных мало и не выполняются требования нормальности распределений случайных величин и другие требования классических методов статистического анализа.

Анализ экологических воздействий

В соответствии с природоохранительным законодательством Российской Федерации, оценка качества окружающей природной среды производится с целью установления предельно допустимых норм воздействия, гарантирующих экологическую безопасность населения, сохранение генофонда и обеспечивающих рациональное использование и воспроизводство природных ресурсов в условиях устойчивого развития хозяйственной деятельности.

Значимость воздействия непосредственно зависит от его вида или природы, физической величины и вероятности его возникновения. Понятие величины охватывает здесь несколько факторов, таких как интенсивность воздействия, продолжительность воздействия, масштаб распространения воздействия. Дополнительным аспектом, который чаще всего не учитывается при оценке значимости воздействий, является

его контекст. Воздействия, одинаковые по величине и вероятности, могут рассматриваться как более или менее важные, влиять на принимаемые решения в большей или меньшей степени в зависимости от того, где именно они имеют место, как они воспринимаются заинтересованными лицами, какова сложившаяся социальная обстановка.

Для оценки значимости существует множество методов, но наиболее простым и часто применяемым методом оценки значимости является сравнение их с универсальными стандартами, который мы будем применять в ходе нашего анализа. Стандарты могут быть количественными или носить характер качественных. Однако следует иметь в виду важные ограничения применимости стандартов для оценки значимости:

- на многие виды воздействия стандарты отсутствуют;
- многие стандарты разработаны на основе приблизительных данных и, таким образом, их область применения ограничена;
- стандарты основаны на представлении о "пороговом воздействии", в то время как многие виды воздействия не имеют порогового значения: не исключено, что их влияние проявляется при сколь угодно малых величинах;
- стандарты не всегда годятся для учета непрямых, кумулятивных воздействий, синергетического действия нескольких факторов;
- стандарты редко применимы для учета уникальных условий, характерных для конкретной ситуации.

Очень близок к сравнению со стандартами метод оценки значимости, основанный на сравнении величины воздействия с усредненными значениями данного параметра для рассматриваемой местности. Такой метод вносит в оценку значимости элемент учета местной ситуации.

К этому типу методов относится сравнение параметров состояния окружающей среды с фоновыми значениями. В свою очередь, сравнение

величины воздействий со стандартами или с характерными значениями является объективным методом оценки значимости воздействий.

Анализ воздействий в рамках экологического мониторинга включает в себя два основных элемента: прогноз их абсолютной физической величины и оценку их относительного вклада. Прогноз величины воздействий обычно осуществляется для различных компонент окружающей среды с применением специальных методов прогноза, таких как математические и статистические модели.

Ранжирование относительной значимости воздействий осуществляется для соотнесения силы их влияния факторов друг с другом. Существует много методов ранжирования относительной значимости, и их выбор зависит от требований программы исследований и конкретной ситуации. В то же время, адекватная оценка значимости воздействий невозможна без соотнесения их эколого-физиологического эффекта с социальными ценностями, интересами и предпочтениями различных заинтересованных сторон.

Превышаемый порог	Характер нарушений	Ранг значимости
Юридический порог	Превышение стандартов, установленных законом	наивысшая значимость
Функциональный порог	Неизбежные воздействия, приводящие к необратимому разрушению экосистем	очень высокая значимость
Порог приемлемости	Воздействия, нарушающие сложившиеся местные нормы	высокая значимость
Порог конфликта	Воздействия, вызывающие конфликт между группами общества по поводу ресурса	умеренная значимость
Порог предпочтений	Воздействия, касающиеся предпочтений тех или иных групп	низкая значимость

Рисунок 2 - Пример шкалы значимости воздействий на экосистемы

Наиболее значимые воздействия превышают установленные стандарты. Это означает, что меры по устранению таких воздействий должны быть приняты в обязательном порядке или намечаемая хозяйственная деятельность не может быть осуществлена. Второй уровень значимости воздействий составляют

неизбежные воздействия, которые необратимым образом разрушают экосистемы [8]. Третьи по значимости воздействия – те, последствия которых нарушают сложившиеся социальные нормы и устои. Наконец, последние две группы воздействий касаются интересов и предпочтений различных групп общества.

ПРАКТИЧЕСКАЯ ЧАСТЬ

Статистическое исследование всегда начинается с подготовки по организации этого исследования. В работу по организации включается статистическое наблюдение, сводка и обработка материалов, а также непосредственно анализ данных.

Первым делом, произведём поиск подходящих данных и составим выборку данных – подмножества всех данных, подходящих для анализа. Согласно требованиям к данным для кластерного анализа, необходимо, чтобы исследуемые данные имели количественные признаки.

В качестве исследуемых данных на вход подаются данные о воздухе, взятые с публичной веб-платформы Kaggle. Данные включают в себя следующие характеристики (все данные представлены в $\text{мкг}/\text{м}^3$):

- SO₂ – уровень диоксида серы;
- CO – уровень окиси углерода;
- NO – уровень оксида азота;
- NO₂ – уровень диоксида азота ;
- PM₂₅ – частицы размером менее 2,5 $\mu\text{м}$;
- PM₁₀ – частицы размером менее 10 $\mu\text{м}$;
- O₃ – уровень озона;
- Station – кодовый номер станции, на которой были собраны сведения, и т.д.

Качество воздуха будем определять, сравнивая содержание элементов из представленных данных с нормой, определённой ВОЗ в “Глобальных рекомендациях ВОЗ по качеству воздуха” [9].

Предобработка данных

Выберем из представленных данных пригодные для нашего анализа. Для этого отсортируем их по станциям, на которых эти данные были собраны и увидим, что наиболее полный спектр элементов был рассмотрен на станции под номером 28079008 (“Escuelas Aguirre”). Значит, данные именно с этой станции

мы будем использовать в ходе нашего анализа. Также исключим показатели веществ, норма для которых не была прописана ВОЗ, в силу недостаточного их влияния на организм человека, которое является определяющим фактором при оценке качества воздуха. В свою очередь, стоит учесть, что мы можем проанализировать комплексное влияние на воздух только тех элементов, чьи средние значения считаются в рамках равных промежутков времени, так как иначе у нас образуются пробелы, которые недопустимы при кластерном анализе.

Таким образом, в выборке остаются только значения уровня диоксида серы, уровня окиси углерода, уровня диоксида азота, содержания частиц размером менее 2,5 мкм, а также частиц размером менее 10 мкм (SO₂, CO, NO₂, PM₂₅ и PM₁₀, соответственно).

Перед импортом данных в сценарий Loginom, обработаем excel-таблицу, удалив лишние столбцы, разбив её на несколько файлов, в каждом из которых добавим столбец, содержащий посчитанное среднесуточное содержание загрязнителя. Подключим импорт получившихся файлов в сценарий Loginom.

С помощью узла Фильтр удалим строки с пустыми значениями среднесуточного значения, объединим все данные, добавив в подмодель узел Соединение.

Определение отклонений

Используя значение норм, определённых ВОЗ (см. Рисунок 5), сравним их со среднесуточными значениями, вычисляя тем самым отклонение от нормы каждого элемента по формуле:

$$\frac{N - S}{N}, \quad (1)$$

где N – нормальное среднесуточное содержание загрязнителя в воздухе,

S – среднесуточное содержание загрязнителя в воздухе.


Загрязнитель	Усредненный период	Промежуточный целевой показатель				Уровень, рекомендуемый в AQG
		1	2	3	4	
ТЧ _{2,5} , мкг/м ³	Ежегодный	35	25	15	10	5
	Суточный ^a	75	50	37,5	25	15
ТЧ ₁₀ , мкг/м ³	Ежегодный	70	50	30	20	15
	Суточный ^a	150	100	75	50	45
О ₃ , мкг/м ³	Пиковый ^b	100	70	–	–	60
	8-часовой ^a	160	120	–	–	100
NO ₂ , мкг/м ³	Ежегодный	40	30	20	–	10
	Суточный ^a	120	50	–	–	25
SO ₂ , мкг/м ³	Суточный ^a	125	50	–	–	40
CO, мкг/м ³	Суточный ^a	7	–	–	–	4

^a 99-й перцентиль (т.е. 3–4 дня с превышением показателей в год).

^b Среднее значение ежедневной максимальной концентрации О₃ за 8-часовой усредненный период в течение шести месяцев подряд с самой высокой за шесть месяцев средней концентрацией О₃.

Рисунок 5 – Норма содержания загрязнителей в воздухе, определённая ВОЗ

Для этого добавим узел “Калькулятор” в наш сценарий. Ниже представлена формула подсчёта отклонений, использованная в калькуляторе, на примере СО.



Соответственно, отрицательные значения отклонения от нормы будут указывать на избыточное содержание загрязнителя в воздухе, что позже мы сможем наглядно увидеть на диаграмме.

Подключим экспорт таблицы с полученными коэффициентами, так как её можно использовать для наглядного демонстрирования результатов анализа.

Кластеризация

С полученными данными мы уже можем сделать некоторые выводы, но для более глубокого исследования проведём кластерный анализ. Добавим в сценарий LogiPlot узел «Кластеризация ЕМ» и перейдем к настройке. На рисунке 6 показана настройка компонента «Кластеризация ЕМ».

Настройка входных столбцов

Фильтрация			
Метка	Имя	Вид данных	Назначение
9.0 dev_CO	dev_CO	Непрерывн...	Используемое
9.0 dev_NO2	dev_NO2	Непрерывн...	Используемое
9.0 dev_SO2	dev_SO2	Непрерывн...	Используемое
9.0 dev_PM25	dev_PM25	Непрерывн...	Используемое
9.0 dev_PM10	dev_PM10	Непрерывн...	Используемое

Рисунок 6 – Выборка данных, принимающая участие в кластеризации

Нормализация данных нам не потребуется, так как в собранных данных не может быть ложных или экстремальных значений: качество воздуха зависит от многих факторов, многие из которых могут колоссально изменить его состав за короткий промежуток времени.

Настройки нормализации

Состояние входа: [Активировать](#)

Разрешить пропущенные значения: ☐

Поле	Нормализатор
Входные	
9.0 dev_CO	Стандартизация
9.0 dev_NO2	Стандартизация

Параметры нормализации

Для данного типа нормализации настройки отсутствуют

Контроль диапазона значений

Метод контроля: Ручная настройка: ☐

Исходный диапазон: Контролируемый диапазон:

Рисунок 7 – Настройки нормализации на примере отклонения окиси углерода

Определим количество кластеров. Пусть для удобства их условно будет три: плохое, среднее и хорошее качество воздуха. Необходимо отметить то, что переменные независимы.

ЕМ Кластеризация

Автоопределение числа кластеров ☐

Заданное число кластеров

Число кластеров

Автоматическое определение числа кластеров

Минимальное число кластеров

Максимальное число кластеров

Порог разделения кластеров

Параметры ЕМ-кластеризации

Переменные независимы ☐

Медианная модификация ☐

Рисунок 8 – Настройка количества кластеров

После выполнения узла представим полученное распределение с помощью профиля кластеров и определим, как кластеры соотносятся с нашим условным распределением.

Фильтрация			Центр кластера			
#	Метка поля	Тип	Итого	Кластер 0	Кластер 1	Кластер 2
			100%	25%	35%	40%
1	9.0 dev_CO	⊙		0,826	0,881	0,884
2	9.0 dev_NO2	⊙		-2,29	-1,32	-0,70
3	9.0 dev_SO2	⊙		0,595	0,707	0,740
4	9.0 dev_PM25	⊙		-0,41	0,108	0,444
5	9.0 dev_PM10	⊙		0,151	0,421	0,670

Рисунок 9 – Профили кластеров

Для презентации кластеров, в целях наглядности, были выбраны их центры. Легко заметить разницу между значениями центров разных кластеров, из которой можно сделать вывод, что кластер 0 включает в себя значения плохого качества воздуха, кластер 1 – значения среднего качества воздуха, кластер 2 – значения хорошего качества воздуха.

Как видно из процентного распределения, целую четверть 2015 года качество воздуха в Мадриде было неудовлетворительным, значит, процент брака составляет 25%.

Визуализация

Проанализируем также, какие элементы в большей степени повлияли на ухудшение качества воздуха: для этого построим графики отклонений всех элементов на одной диаграмме (см. Рисунок 10)




Рисунок 10 – Графики отклонений всех элементов на протяжении года

Как видно из графика, наибольшее отклонение в отрицательную сторону, по сравнению с остальными элементами, имеет NO₂. Также на общее неудовлетворительное состояние воздуха повлиял избыток PM₂₅ и PM₁₀ – в гораздо меньшей степени.

Таким образом, мы завершили практическую часть нашей исследовательской работы и можем подвести итоги ее выполнения.

ЗАКЛЮЧЕНИЕ

Известно, что человек негативно воздействует на природу: сжигает леса, осушает реки, меняет баланс в экосистемах, трансформирует ландшафт местности, где живет. Однако, с повышением экологической сознательности, у людей появилась цель уменьшать своё пагубное влияние на окружающий мир. Для нахождения способов по достижению этой цели необходимо анализировать природные характеристики, впоследствии выявляя степень своего влияния на них.

Так NO_2 , который в ходе выполненного анализа проявил себя как химическое соединение, наиболее сильно ухудшающее состояние воздуха, занимает одно из первых мест в числе распространенных выбросов в атмосферу антропогенного происхождения. Источники образования оксидов азота – выхлопы автомобильного транспорта, продукты сгорания тепловых электростанций. Длительное воздействие диоксида азота на человеческий организм может спровоцировать заболевания лёгких, помимо этого, оно очень негативно сказывается на растительности.

В свою очередь, избыток твёрдых частиц, выявленный в ходе анализа, при долгосрочном воздействии на организм человека может привести к значительному сокращению продолжительности жизни, прежде всего в связи с увеличением сердечно-легочных заболеваний и смертности от рака легких. Загрязнение воздуха ТЧ связывают с ростом болезней нижних дыхательных путей и снижение функции легких у детей, а также с хронической обструктивной болезнью легких и снижением функции легких у взрослых.

В результате данного курсового проекта проведен кластерный анализ природной характеристики на примере воздуха Мадрида, сделаны выводы относительно главных причин загрязнения и его последствия.

Цель – провести кластерный анализ по качеству воздуха на примере воздуха в Мадриде за 2015 год – достигнута.

В ходе данной курсовой работы выполнены следующие задачи:

- изучена научная и методическая литература по проблеме кластеризации данных, качественного анализа и анализа экологической обстановки;
- выполнена предобработка данных;
- использованы знания математической статистики с применением современных средств обработки данных: аналитической платформы Loginom, функционального инструмента визуализации и анализа данных Microsoft Excel;
- выполнена кластеризация данных;
- пройдено обучение качественному оформлению документации.

СПИСОК ИСПОЛЬЗУЕМЫХ ИСТОЧНИКОВ

1. Миркин Б.Г., Введение в анализ данных. Учебник и практикум / Миркин Б.Г. – Москва: Юрайт, 2015. – 176 с.
2. Гитис Л.Х., Статистическая классификация и кластерный анализ / Гитис Л.Х. – Москва: Издательство МГГУ, 2003. – 157 с.
3. Дюран Б., Кластерный анализ / Дюран Б., Оделл П., Демиденко Е.З. – Москва: Книга по Требованию, 2012. – 128 с.
4. Другов Ю.С., Газохроматографический анализ загрязненного воздуха. Практическое руководство / Другов Ю.С., Родин А.А. – Москва: Лаборатория Знаний, 2015. – 528 с.
5. Актуальные проблемы наук о Земле: использование природных ресурсов и сохранение окружающей среды – Брест: БрГУ, 2017. — 295 с.
6. Защита атмосферы от промышленных выбросов : учебно-методическое пособие / В. Н. Марцуль. — Минск: БГТУ, 2016. — 258 с.
7. Оценка воздействия на окружающую среду и экологическая экспертиза: учебно-методический комплекс / Е. В. Нисковская. — Москва: Проспект, 2017. — 192 с.
8. Экологический мониторинг: учебное пособие / О. В. Дудник. — Старый Оскол: ТНТ, 2017. — 231 с.
9. Глобальные рекомендации ВОЗ по качеству воздуха: касающиеся твердых частиц, озона, двуокиси азота, двуокиси серы и окиси углерода / ВОЗ. — Женева: Всемирная организация здравоохранения, 2021. – 273 с.
10. Публичная веб-платформа “Kaggle” [Электронный ресурс] / Air Quality in Madrid (2001-2018). — Режим доступа: <https://www.kaggle.com/decide-soluciones/air-quality-madrid/>. — Загл. с экрана. — Яз. англ.

ПРИЛОЖЕНИЕ

На рисунке 11 представлен итоговый сценарий проекта на аналитической платформе Loginom.




Рисунок 11 – Итоговый сценарий Loginom

Описание сценария:

1. Импорт файла с данными
2. Предобработка
3. Кластеризация и визуализация полученных результатов




Рисунок 12. Сценарий подмодели

Описание подмодели:

1. Импорт excel-таблиц
2. Фильтры строк
3. Объединение данных
4. Калькулятор, где подсчитываются отклонения от нормы